

# کاربرد یادگیری عمیق برای پیش بینی حمله قلبی با هوش مصنوعی قابل توضیح

الیاس دریتزاس\* و ماریا تریگکا

مرکز تحقیقات و نوآوری آتنا، موسسه سیستم های صنعتی (ISI)، 26504 پاتراس، یونان؛ trigka@isi.gr  
\* مکاتبات: dritsas@isi.gr

**چکیده:** بیماری قلبی همچنان یکی از علل اصلی مرگ و میر در سراسر جهان است و پیش بینی به موقع و دقیق حمله قلبی به دلیل پیچیدگی این بیماری و محدودیت های روش های تشخیصی سنتی، بسیار مهم اما چالش برانگیز است. این چالش ها شامل نیاز به تشخیص های منابع بر و دشواری در تفسیر مدل های پیش بینی پیچیده در محیط های بالینی است. در این مطالعه، ما عملکرد پنج مدل شناخته شده یادگیری عمیق (DL)، یعنی پرسپترون چندلایه (MLP)، شبکه عصبی کانولوشن (CNN)، شبکه عصبی بازگشتی (RNN)، حافظه کوتاه مدت بلندمدت (LSTM)، واحد بازگشتی دروازه دار (GRU) و یک مدل ترکیبی را بر روی یک مجموعه داده پیش بینی حمله قلبی اعمال و مقایسه می کنیم. هر مدل به درستی با استفاده از دقت، صحت، فراخوانی، امتیاز F1 و مساحت زیر منحنی مشخصه عملیاتی گیرنده (AUC) به عنوان معیارهای عملکرد تنظیم و ارزیابی شد. علاوه بر این، با ادغام یک تکنیک هوش مصنوعی قابل توضیح (XAI)، به ویژه توضیحات افزایشی شیلی (SHAP)، قابلیت تفسیر پیش بینی ها را افزایش می دهیم و آنها را برای متخصصان مراقبت های بهداشتی قابل اجرا می کنیم و در نتیجه کاربرد بالینی را افزایش می دهیم. نتایج آزمایش نشان داد که مدل هیبریدی (Hybrid) با دستیابی به بالاترین عملکرد در تمام معیارها، بر مدل قبلی برتری دارد. به طور خاص، مدل هیبریدی به دقت ۹۱٪، دقت ۸۹٪، میزان بازخوانی ۹۰٪، امتیاز F1 ۸۹٪ و سطح زیر منحنی (AUC) ۰.۹۵ دست یافت. این نتایج، توانایی برتر مدل هیبریدی را در پیش بینی حملات قلبی، به دلیل مدیریت کارآمد داده های متوالی و وابستگی های بلندمدت، برجسته کرد.

**کلمات کلیدی:** حمله قلبی؛ یادگیری عمیق؛ XAI؛ SHAP؛ سلامت الکترونیک؛ پیش بینی؛ تحلیل داده ها



**استناد:** دریتزاس، ای.؛ تریگکا، ام. کاربرد

یادگیری عمیق برای پیش بینی حمله قلبی با

هوش مصنوعی قابل توضیح. کامپیوترها ۲۰۲۴،

10.3390/computers13100244/13

https://doi.org/10.3390/computers13100244/13

## ۱. مقدمه

بیماری قلبی همچنان علت اصلی مرگ و میر در سراسر جهان است و حملات قلبی یکی از تظاهرات غالب و شدید این بیماری است. پیش بینی به موقع و دقیق حملات قلبی می تواند با امکان مداخله زود هنگام و مراقبت های پزشکی مناسب، میزان مرگ و میر را به میزان قابل توجهی کاهش دهد. [۲،۱].

حمله قلبی که در پزشکی به عنوان انفارکتوس میوکارد شناخته می شود، زمانی رخ می دهد که جریان خون به بخشی از قلب برای مدت طولانی مسدود شود، به طوری که بخشی از عضله قلب آسیب ببیند یا بمیرد. این اغلب ناشی از تجمع چربی، کلسترول و سایر مواد است که پلاکی را در شریان های کرونری که قلب را تغذیه می کنند (بیماری عروق کرونر) تشکیل می دهند. هنگامی که پلاکی در شریان قلب پاره می شود، لخته خون در اطراف پلاک تشکیل می شود. اگر لخته به اندازه کافی بزرگ شود، می تواند جریان خون را از طریق شریان کرونری تا حد زیادی یا به طور کامل مسدود کند. [۴،۳].

اگر انسداد به سرعت برطرف نشود، بخشی از عضله قلب که توسط شریان تغذیه می شود، شروع به مردن می کند. بافت سالم قلب با بافت اسکار جایگزین می شود که بر توانایی قلب در پمپاژ مؤثر تأثیر می گذارد و می تواند منجر به عوارض مادام العمر و نارسایی احتمالی قلب شود. علائم حمله قلبی می تواند بسیار متفاوت باشد، از درد ناگهانی و شدید قفسه سینه کلاسیک گرفته تا علائم ظریفی که ممکن است شامل ناراحتی قفسه سینه، تپش قلب، درد قسمت بالای بدن، حالت تهوع و تنگی نفس باشد. مراقبت پزشکی فوری می تواند در بازگرداندن جریان خون و به حداقل رساندن آسیب به بافت قلب بسیار مهم باشد. [۶،۵].

ویراستار آکادمیک: پائولو بلاویستا

دریافت: ۳۱ ژوئیه ۲۰۲۴ اصلاح شده:

۱۸ سپتامبر ۲۰۲۴ پذیرفته شده: ۲۳

سپتامبر ۲۰۲۴ منتشر شده: ۲۵ سپتامبر

۲۰۲۴

**حق نشر:** © ۲۰۲۴ توسط نویسندگان. دارنده

مجوز MDPI، باز، سوئیچس. این مقاله یک

مقاله با دسترسی آزاد است که تحت شرایط و

ضوابط مجوز 4.0/licenses/by/

https://creativecommons.org/licenses/by/4.0/

Creative Commons Attribution (CC)

توزیع شده است.

پیشرفت در درمان پزشکی، میزان بقا و کیفیت زندگی قربانیان حمله قلبی را بهبود بخشیده است. مداخلات اورژانسی مانند آنژیوپلاستی و پیوند بای پس عروق کرونر می تواند جریان خون را به قلب بازگرداند. داروهایی مانند ترومبولیتیک ها می توانند لخته های خونی را که شریان های کرونری را مسدود می کنند، حل کنند. درمان های پس از حمله قلبی ممکن است شامل توانبخشی قلبی، تنظیم سبک زندگی و رژیم های دارویی برای مدیریت عوامل خطر و جلوگیری از حملات بعدی باشد. آموزش مداوم بیمار در مورد شناخت علائم و مدیریت مؤثر سلامت، نقش مهمی در بهبود نتایج و جلوگیری از حوادث آینده دارد. [۸،۷].

در سال های اخیر، کاربرد یادگیری ماشینی (DL) در تشخیص های پزشکی، به ویژه در پیش بینی شرایط بحرانی مانند حملات قلبی، پتانسیل فوق العاده ای از خود نشان داده است. با این حال، یکی از چالش های مهم در به کارگیری این مدل ها در عمل بالینی، قابلیت تفسیر آن ها است. متخصصان مراقبت های بهداشتی نه تنها به پیش بینی های دقیق، بلکه به درک روشنی از چگونگی انجام این پیش بینی ها برای اعتماد و عمل به آن ها نیز نیاز دارند. تکنیک های XAI با شفاف و قابل تفسیر کردن فرآیند تصمیم گیری مدل های پیچیده، به عنوان ابزارهای حیاتی در پرداختن به این چالش ظهور کرده اند [۹-۱۱]. در میان این تکنیک ها، SHAP برجسته است. مقادیر SHAP، که ریشه در نظریه بازی های مشارکتی دارند، معیاری یکپارچه از اهمیت ویژگی ها ارائه می دهند و تأثیر هر ویژگی را بر خروجی مدل کمی می کنند. با ادغام SHAP در فرآیند پیش بینی، این مطالعه نه تنها دقت پیش بینی های حمله قلبی را با استفاده از مدل های پیشرفته یادگیری ماشینی افزایش می دهد، بلکه تضمین می کند که این پیش بینی ها برای متخصصان مراقبت های بهداشتی قابل فهم و عملی هستند. [۱۲،۱۳].

انگیزه اصلی این کار، پرداختن به نیاز حیاتی برای پیش بینی دقیق و به موقع حملات قلبی است که همچنان یکی از علل اصلی مرگ و میر در سطح جهان است. روش های سنتی برای تشخیص و پیش بینی حملات قلبی، اگرچه مؤثر هستند، اما اغلب به زمان و منابع قابل توجهی نیاز دارند و ممکن است همیشه هشدارهای اولیه لازم برای جلوگیری از پیامدهای نامطلوب را ارائه ندهند. با بررسی قابلیت های مدل های یادگیری عمیق (DL)، هدف ما مهار قدرت تکنیک های محاسباتی پیشرفته برای بهبود دقت و کارایی پیش بینی است. این مطالعه با پتانسیل افزایش فرآیندهای تصمیم گیری بالینی، کاهش بار سیستم های مراقبت های بهداشتی و در نهایت نجات جان انسان ها با امکان تشخیص زودهنگام و دقیق تر خطرات حمله قلبی انجام می شود.

این کار چندین سهم قابل توجه در حوزه تشخیص پزشکی و تجزیه و تحلیل پیش بینی کننده دارد:

- ما مقایسه ای جامع از پنج مدل برجسته یادگیری ماشینی (DL)، شامل MLP، CNN، RNN، LSTM، GRU، و یک مدل ترکیبی در زمینه پیش بینی حمله قلبی ارائه می دهیم. این تجزیه و تحلیل به شناسایی نقاط قوت و ضعف هر مدل کمک می کند و بینش های ارزشمندی در مورد مناسب بودن آنها برای کاربردهای پزشکی ارائه می دهد.
- با ارزیابی مدل ها با استفاده از طیف وسیعی از معیارهای ارزیابی، از جمله دقت، دقت، یادآوری، امتیاز F1 و AUC، ارزیابی کاملی از عملکرد آنها را تضمین می کنیم. این رویکرد چندوجهی، درک جامع تری از اثربخشی هر مدل در پیش بینی حملات قلبی ارائه می دهد.
- این مطالعه مراحل کلیدی روش شناسی اتخاذ شده، شامل پیش پردازش داده ها، فرآیندهای بهینه و اندازه گیری اهمیت ویژگی ها را با فرض تقسیم آموزش-آزمون ۸۰-۲۰، برای اطمینان از ارزیابی قوی و قابل اعتماد مدل ارائه می دهد.
- با استفاده از SHAP، یک تکنیک XAI، این مطالعه بینش های شفاف و قابل تفسیری در مورد فرآیندهای تصمیم گیری مدل های DL ارائه می دهد و پیش بینی ها را قابل فهم تر و قابل اعتمادتر می کند.
- نتایج این مطالعه، بینش های عملی برای متخصصان مراقبت های بهداشتی و محققان ارائه می دهد و مشخص می کند که کدام مدل های یادگیری عمیق (DL) ممکن است برای پیش بینی حمله قلبی مؤثرتر باشند. این بینش ها می توانند تحقیقات آینده و توسعه ابزارهای پیش بینی در محیط های بالینی را هدایت کنند و به بهبود نتایج بیمار کمک کنند.

این مقاله پژوهشی به شرح زیر ساختار یافته است. در بخش ۲، ما آثار مرتبط با موضوع را بررسی می کنیم. بخش ۳ جزئیات مجموعه داده های مورد استفاده را شرح داده و روش شناسی اتخاذ شده را بررسی می کند. بخش ۴ نتایج تجربی مدل های یادگیری ماشین را ارائه داده و عملکرد آنها را ارزیابی می کند. در نهایت، بخش ۵ یافته های تحقیق ما را خلاصه می کند و مسیرهای بالقوه آینده را مورد بحث قرار می دهد.

## ۲. کارهای مرتبط

در سال های اخیر، کاربرد تکنیک های یادگیری ماشینی و یادگیری عمیق در تشخیص های پزشکی، به ویژه در پیش بینی حملات قلبی، توجه قابل توجهی را به خود جلب کرده است. مطالعات متعددی مدل ها و رویکردهای مختلفی را برای بهبود دقت و قابلیت اطمینان پیش بینی های حمله قلبی بررسی کرده اند و بر نیاز به راه حل های قابل تفسیر و از نظر بالینی قابل اجرا تأکید دارند. اولاً، سهم کار [۱۴] در توسعه یک سیستم پیش بینی خودکار بیماری قلبی با استفاده از یک مدل شبکه عصبی عمیق (DNN) نهفته است. این مدل پیشنهادی، ناهنجاری های کلیدی در روش های قبلی مانند مسائلی مربوط به دقت و نیاز به پیش پردازش دستی داده ها را با پیاده سازی یک مرحله پیش پردازش کاملاً خودکار داده ها، برطرف می کند. اثربخشی مدل بر روی یک مجموعه داده از مخزن UCI، کلیوند، آزمایش شد و به حداقل دقت ۸۷.۶۴٪ دست یافت که از سایر الگوریتم های ML بهتر عمل می کند. با بهره گیری از پیچیدگی و قابلیت های استخراج ویژگی DL، این روش پیش بینی های قابل اعتمادتری را نوید می دهد و فرصت هایی را برای پیشرفت های آینده در تجزیه و تحلیل داده های پزشکی با استفاده از تکنیک های DL فراهم می کند.

کارپیشنهادی [۱۵] از CNN برای افزایش دقت پیش بینی بیماری قلبی با استفاده از مجموعه داده کلیوند استفاده می کند. مدل CNN با یک لایه ورودی متراکم از ۱۲۸ نورون و دو لایه پنهان با اندازه های تجمع خاص طراحی شده است و از بهینه ساز Adam برای مدیریت نویز و مسائلی گرایان پراکنده استفاده می کند. نتایج تجربی، دقت پیش بینی بالای ۷۵.۲٪ را نشان می دهد که نشان دهنده اثربخشی CNN در این حوزه است. این مدل به طور قابل توجهی معیارهای خطا را کاهش می دهد و آن را به ابزاری قوی برای تشخیص زودهنگام بیماری قلبی تبدیل می کند و به طور بالقوه با امکان مداخله پزشکی به موقع، جان بسیاری را نجات می دهد.

علاوه بر این، کار [۱۶] مجموعه ای از الگوریتم های یادگیری ماشینی و تکنیک های یادگیری ماشینی را برای پیش بینی بیماری قلبی با دقت بالا ادغام می کند. با استفاده از الگوریتم هایی مانند طبقه بندی کننده جنگل تصادفی (RF) و یک مدل یادگیری ماشینی سفارشی، این مطالعه به بهبود قابل توجهی در دقت دست یافت. مدل یادگیری ماشینی با استفاده از نمونه گیری بیش از حد برای متعادل کردن مجموعه داده ها، عملکرد برتر را با دقت ۹۲.۳۵٪، دقت ۹۰.۸۴٪، فراخوانی ۹۴.۲۰٪ و امتیاز F1 ۹۲.۴۹٪ نشان داد. از یک مجموعه داده برگرفته از سیستم نظارت بر عوامل خطر رفتاری (BRFSS) استفاده شد که ۱۹ متغیر مربوط به عوامل سبک زندگی یک فرد را که می توانند در معرض خطر ابتلا به هر نوع بیماری قلبی عروقی باشند، در خود نگه می دارد.

یک شبکه عصبی عمیق CNN به نام CardioHelp به طور مؤثر احتمال بیماری قلبی عروقی را پیش بینی می کند. [۱۷]. این مدل با دستیابی به دقت پیش بینی ۹۴.۷۸٪، که به طور قابل توجهی بالاتر از تکنیک های قبلی است، از روش های موجود پیشی می گیرد. معماری CNN از لایه های کانولوشن و ادغام برای مدیریت مدل سازی داده های زمانی استفاده می کند و پیش بینی را در مراحل اولیه بهبود می بخشد. نتایج تجربی نشان می دهد که CardioHelp نه تنها دقت، بلکه عملکرد کلی را در مقایسه با روش های پیشرفته بهبود می بخشد و آن را به ابزاری قوی برای تشخیص زودهنگام بیماری های قلبی تبدیل می کند.

به طور مشابه، مرجع [۱۸] یک مدل ترکیبی را ارائه می دهد که ترکیبی از ماشین بردار پشتیبان (SVM)، K-نزدیک ترین همسایه ها (K-NN) و درخت های تصمیم گیری (DT) برای پیش بینی بیماری قلبی است و به دقت ۹۵.۵٪ دست می یابد. این مدل به طور بهینه نقاط قوت هر الگوریتم را ادغام می کند و در نتیجه عملکرد پیش بینی را افزایش می دهد. از یک مجموعه داده شناخته شده بیماری قلبی استفاده شده و با دقت پیش پردازش شده است تا از قابلیت اطمینان و اعتبار آن اطمینان حاصل شود. با اجرای یک رویکرد لایه ای، این مدل به طور مؤثر خطاهای پیش بینی را به حداقل می رساند و ابزاری قوی برای تصمیم گیری بالینی ارائه می دهد. تجزیه و تحلیل مقایسه ای، برتری آن را نسبت به مدل های سنتی برجسته می کند و پتانسیل قابل توجه آن را برای کاربردهای پزشکی در دنیای واقعی نشان می دهد.

کار تحقیقاتی [۱۹] از یک شبکه عصبی عمیق (DNN) با بهینه سازی فراپارامتری (TO) تالوس برای پیش بینی بیماری قلبی استفاده کردند. این مدل خاص به دقت طبقه بندی ۹۰.۷۸٪ دست یافت که از الگوریتم های دیگری مانند K-NN با ۹۰.۱۶٪، رگرسیون لجستیک با ۸۵.۲۵٪ و SVM با ۸۱.۹۷٪ بهتر عمل می کند. این رویکرد، اثربخشی بهینه سازی تالوس را در افزایش دقت پیش بینی نشان می دهد و آن را به ابزاری قوی برای تشخیص زودهنگام بیماری قلبی تبدیل می کند. دقت بالای این مدل می تواند به طور قابل توجهی در مداخله درمان به موقع بیماران کمک کند.

علاوه بر این، مرجع [۲۰] از یک نسخه اصلاح شده از شبکه های عصبی مصنوعی (ANN) سنتی، شبکه عصبی اصلاح شده با یادگیری عمیق (DLMNN)، که بهبود یافته است، استفاده کرد.

با استفاده از الگوریتم بهینه سازی ماهی مرکب (CFOA) برای دقت بهتر. مجموعه داده های بیماری قلبی مجارستان از مخزن UCI به عنوان معیاری برای آموزش مدل انتخاب شد. این داده ها دارای ویژگی های مشابه کلیولند هستند، به جز ویژگی ای که تعداد رگ های اصلی را ثبت می کند. داده های واقعی بیمار که از طریق شبکه حسگر IoT جمع آوری شده اند، برای تشخیص وجود بیماری با استفاده از DLMNN مورد استفاده قرار گرفتند و به دقت 96.8٪، همراه با ویژگی بالای 85٪، حساسیت 98.13٪ و امتیاز F1 98.3٪ دست یافتند که از ANN عملکرد بهتری دارد.

نویسندگان در [۲۱] یک مدل پیش بینی مبتنی بر یادگیری ماشینی (DL) و به ویژه شبکه عصبی مصنوعی (ANN) را برای پیش بینی بیماری های قلبی عروقی پیشنهاد می دهند. مدل شبکه عصبی مصنوعی با یک لایه ورودی ۱۳ گره ای، یک لایه پنهان ۴ گره ای و یک لایه خروجی نهایی طراحی شده است که با استفاده از بهینه ساز آدام و تابع زیان آنتروپی متقاطع دودویی بهینه سازی شده است. شبکه عصبی مصنوعی به دقت 85.24 درصد رسیده است که از مدل های سنتی یادگیری ماشین مانند (SVM) 81.97٪ و (DT) 81.97٪ (از نظر دقت) بهتر عمل می کند. عملکرد شبکه عصبی مصنوعی از نظر سایر معیارها شامل دقت، فراخوانی و امتیاز F1 برابر با ۰.۸۵ است که نشان دهنده استحکام و اثربخشی آن در پیش بینی بیماری قلبی است. در نهایت، به مرجع [۲۲] یک مدل DL مبتنی بر SMOTE کارآمد برای پیش بینی حمله قلبی معرفی می کند که به دقت 96.۱٪ دست می یابد. این مدل از تکنیک نمونه گیری بیش از حد اقلیت مصنوعی (SMOTE) برای رفع عدم تعادل داده ها استفاده می کند و از یک شبکه عصبی مصنوعی (ANN) بدون نیاز به مهندسی ویژگی گسترده استفاده می کند. مدل ANN با مقادیر دقت و فراخوانی 95.7٪ و امتیاز F1 عملکرد برتر را نشان داد. این رویکرد از سایر مدل های یادگیری ماشین و سیستم های موجود بهتر عمل کرد و قابلیت اطمینان و اثربخشی بالایی را در پیش بینی حملات قلبی نشان داد و در عین حال هزینه های محاسباتی را به حداقل رساند.

میزان رویکرد پیشنهادی را با کارهای مرتبط مقایسه می کند و بر مجموعه داده ها، مدل و معیار عملکرد تأکید دارد. جدول نشان می دهد که چگونه رویکرد پیشنهادی از مدل های موجود در یک معیار کلیدی AUC (که سایر کارها آن را فرض نکرده اند) متمایز است، در حالی که به نیاز حیاتی برای شفافیت مدل از طریق ادغام SHAP نیز می پردازد. این مقایسه مزایای روش ما را هم از نظر قدرت پیش بینی و هم از نظر کاربرد بالینی برجسته می کند و آن را از مدل های مورد بحث در کارهای مرتبط متمایز می کند. برای مقایسه عملکرد منصفانه بین مدل های رایج در هر کار و مطالعه ما، باید از همان مجموعه داده ها، پیش پردازش، تنظیم و روش های آموزشی استفاده می شد. به عنوان مثال، استفاده از SMOTE همانطور که در [نشان داده شده است] بسیار به عملکرد مدل کمک می کند. [۲۲]، که در آن از همان مجموعه داده ها استفاده شده است، اما در کار ما، چنین روشی اعمال نشده است، بنابراین نمی توان مقایسه های ساده ای انجام داد.

جدول ۱. مقایسه آثار مرتبط.

مرجع	مجموعه داده ها	تعداد ویژگی ها	مدل	متریک
[۱۴]	کلیولند	۱۴	دی ان ان	دقت ۸۷.۶۴٪
[۱۵]	کلیولند	۱۴	سی ان ان	دقت ۷۵.۲٪
[۱۶]	باف از اس اس	۱۹	و نمونه گیری بیش از حد DL	دقت ۹۲.۳۵٪، دقت ۹۰.۸۴٪، میزان بازیابی ۹۴.۲۰٪، امتیاز F1 ۹۲.۴۹٪
[۱۷]	کلیولند	۱۴	سی ان ان عمیق	دقت ۹۴.۷۸٪
[۱۸]	کلیولند	۱۴	دی ال	دقت ۹۴.۲٪، میزان بازیابی ۸۲.۳٪، ویژگی ۸۳.۱٪
[۱۹]	کلیولند	۱۴	دی ان ان	دقت ۹۰.۷۸٪
[۲۰]	مجارستانی	۱۳	DLMNN	دقت ۹۷٪، ویژگی ۸۵٪، میزان یادآوری ۹۸.۱۳٪، امتیاز F1 ۹۸.۳٪
[۲۱]	کلیولند	۱۴	شبکه عصبی مصنوعی (ANN)	دقت ۸۵.۲۴٪
[۲۲]	کلیولند	۱۴	یادگیری ماشین مبتنی بر SMOTE مدل	دقت ۹۶.۱٪، امتیاز F1 96.0٪، دقت و فراخوانی ۹۶.۱٪
پیشنهادی	کلیولند	۱۴	مدل ترکیبی (CNN، SHAP یا GRU)	دقت ۹۱٪، دقت ۸۹٪، میزان فراخوانی ۹۰٪، امتیاز F1 ۸۹٪، AUC 0.95

باین حال، مزایای متمایز آن نسبت به رویکردهای ذکر شده در بالا عبارتند از:

- با ترکیب CNN و GRU، این مدل به طور مؤثر ویژگی های مکانی و زمانی را ثبت می کند. علاوه بر این، معماری مدل به گونه ای طراحی شده است که الگوهای پیچیده را در داده های متوالی (پزشکی) مدیریت کند و آن را در برابر سناریوهای بالینی متنوع مقاوم تر سازد (جزئیات بیشتر در بخش ... ارائه شده است).
- این مدل با استفاده از معیارهای چندگانه - دقت، صحت، بازخوانی، امتیاز F1 و AUC - ارزیابی می شود که برخلاف بسیاری از مطالعات که بر روی یک معیار واحد تمرکز می کنند، ارزیابی کاملی از عملکرد آن را تضمین می کند.
- ادغام SHAP بینش های شفافیتی در مورد فرآیند تصمیم گیری مدل ارائه می دهد و به نیاز حیاتی برای تفسیرپذیری در محیط های بالینی که اکثر مدل های دیگر فاقد آن هستند، پاسخ می دهد. با افزایش عملکرد و تفسیرپذیری، این مدل برای پیاده سازی بالینی در دنیای واقعی مناسب تر است و آن را به گزینه ای مناسب تر برای بهبود نتایج بیمار تبدیل می کند.

به طور خلاصه، این مزایای ترکیبی، رویکرد پیشنهادی را نه تنها از نظر فنی برتر، بلکه با نیازهای عملی متخصصان مراقبت های بهداشتی نیز همسوتر می کند و آن را از سایر روش های موجود در مقالات متمایز می سازد.

### ۳. مواد و روش ها

در ابتدا، ما بر توصیف و تحلیل مجموعه داده ها تأکید کردیم. سپس، بر مراحل کلیدی روش شناختی به کاررفته در این مطالعه تمرکز کردیم: آماده سازی داده ها، آموزش مدل، ارزیابی و کاربرد تکنیک XAI. هر مرحله با دقت اجرا شد تا از قابلیت اطمینان و استحکام نتایج اطمینان حاصل شود.

#### ۳.۱. توصیف و تحلیل مجموعه داده های حمله قلبی

مجموعه داده ها [۲۳] که ما به آن تکیه کردیم شامل ۱۴ ویژگی و ۳۰۳ نمونه (کلیولند)، شامل ۶ ویژگی دسته بندی شده، ۲ ویژگی اسمی (بله/خیر، مرد/زن) و ۶ ویژگی عددی است. یک نسخه کمی اصلاح شده از این مجموعه داده با حذف تنها ۶ ردیف با مقادیر گمشده استفاده شد؛ بنابراین مجموعه ای از ۲۹۷ نمونه پدیدار شد. جزئیات مجموعه داده به دست آمده در جدول ارائه شده است.

مجموعه داده مورد استفاده در این مطالعه به دلیل تعادل ویژگی ها و نمونه ها انتخاب شد، که پیچیدگی قابل کنترلی را برای توسعه و مقایسه مدل اولیه فراهم می کند، در حالی که مخازن مجموعه داده جایگزین [۲۴]-[۲۶] با ارائه حجم نمونه بزرگتر (مجموعه داده های افزوده تولید شده از طریق تکثیر نمونه با استفاده از طبقه بندی کننده های یادگیری ماشین متنوع) یا مجموعه ویژگی های مختلف، مجموعه داده انتخاب شده برای اطمینان از کاوش متمرکز عملکرد مدل با یک مجموعه ویژگی با اندازه متوسط که شامل متغیرهای بالینی حیاتی است، انتخاب شد. این امر امکان ارزیابی دقیق قابلیت های مدل را قبل از مقیاس بندی به مجموعه داده های بزرگتر و پیچیده تر فراهم کرد.

این شامل افراد ۲۹ تا ۷۷ ساله است که بیماران مرد با مقدار جنسیتی بله و بیماران زن با مقدار خیر نشان داده شده اند. چهار نوع درد قفسه سینه ثبت شده است: درد قفسه سینه معمولی (ناشی از کاهش جریان خون به دلیل تنگی عروق کرونر)، درد قفسه سینه غیرمعمول و غیر آنژینی (ناشی از علل مختلف و ممکن است نشان دهنده بیماری قلبی نباشد) و آنژین بدون علامت که ممکن است به بیماری قلبی نیز مربوط نباشد. ویژگی های اضافی شامل RestBP (فشار خون در حالت استراحت)، Chol (سطح کلسترول سرم)، FastBS (با مقادیری که در صورت قند خون ناشتا بالاتر از ۱۲۰ میلی گرم در دسی لیتر، بله و در صورت کمتر بودن، خیر تعیین می شوند)، RestECG (نتیجه الکتروکاردیوگرافی در حالت استراحت)، MaxHR (حداکثر ضربان قلب به دست آمده)، ExIndAgina (آنژین ناشی از ورزش، که در صورت وجود درد، بله و در غیر این صورت خیر ثبت می شود)، STD (افت ST ناشی از ورزش)، شیب (شیب اوج قطعه ST در ورزش)، NMajV (تعداد رگ های اصلی که توسط فلوروسکوپی رنگ آمیزی می شوند)، Thal (یک اختلال خونی به نام تالاسمی) و حمله قلبی (ویژگی کلاس، با مقدار خیر برای حالت طبیعی و بله برای نشان دادن عدم وجود یا وجود حمله قلبی).

در زیربخش های بعدی، تحلیل ویژگی هایی که وقوع حمله قلبی را نشان می دهند، به دو بخش عددی و اسمی تقسیم می کنیم. در مورد ویژگی هایی با مقادیر عددی، ما به طور خاص دو گروه مشاهده شده (بله، خیر) را با هم مقایسه می کنیم و یک تصویر گرافیکی سطح بالا از حداقل، چارک ۲۵٪، میانه (یا چارک ۵۰٪)، میانگین،



اطلاعات چارک ۷۵٪ و حداکثر، همچنین تقارن، چولگی، واریانس و داده های پرت دو گروه را آشکار می کند. در مورد ویژگی های اسمی، مقادیر آنها (داده های دسته بندی شده) و شیوع در هر گروه ارائه و به درستی مورد بحث قرار گرفته است.

جدول ۲. اطلاعات ویژگی در مجموعه داده ها.

نام ویژگی	نوع	توضیحات	محدوده مقادیر
سن	عددی	سن فرد - سال	۷۷-۲۹
سکس	اسمی	جنسیت فرد	مرد، زن
چست پی	دسته بندی	نوع درد قفسه سینه (نوع آنژین)	درد تپیک، آتیپیک، غیر آنژینی، بدون علامت
استراحت بی بی	عددی	فشار خون در حالت استراحت— میلی متر/جیوه	۲۰۰-۹۴
چول	عددی	کلسترول سرم— میلی گرم در دسی لیتر	۵۶۴-۱۲۶
فست بی اس	اسمی	قند خون ناشتا— میلی گرم در دسی لیتر	نه، بله
استراحت خوار قلب (RestECG)	دسته بندی	نتایج ECG در حالت استراحت	طبیعی، هیپرتروفی، غیر طبیعی بودن موج ST-T
مکس اچ آر	عددی	حداکثر ضربان قلب ثبت شده— bpm	۲۰۲-۷۱
ExIndAng	اسمی	آنژین ناشی از ورزش	نه، بله
STDp	عددی	افت ST ناشی از ورزش نسبت به استراحت	۶.۲-۰.۰
شیب	دسته بندی	شیب قطعه ST تمرین اوج	شیب نزولی، مسطح، شیب صعودی
NMajV	عددی	تعداد رنگ های اصلی رنگ آمیزی شده توسط فلوروسکوپی	۳، ۲، ۱، ۰
تال	دسته بندی	سطح اختلال تالاسمی	عیب معمولی، عیب ثابت، عیب برگشت پذیر
حمله قلبی	اسمی	متغیر کلاس هدف، وجود یا عدم وجود حمله قلبی را نشان می دهد.	نه، بله

### ۳.۱.۱. حمله قلبی و توزیع ویژگی های عددی با استفاده از نمودارهای جعبه ای

اولین نمودار جعبه ای از (شکل ۱) مربوط به ویژگی «سن» برای کلاس های «بدون حمله قلبی» (آبی) و «بله حمله قلبی» (نارنجی) است. برای کلاس «بدون حمله قلبی»، میانگین سنی ۵۸ سال است، با دامنه بین چارکی (IQR) از ۵۲ سال تا ۶۲ سال. حداقل سن ۳۸ سال و حداکثر سن ۷۷ سال است، با میانگین سنی ۵۶.۷۰ سال، همانطور که با علامت ضربدر نشان داده شده است. یک مقدار پرت در ۳۵ سال وجود دارد که نشان می دهد تعداد کمی از افراد به طور قابل توجهی جوان تر از بقیه گروه هستند. این نشان دهنده دامنه سنی نسبتاً وسیعی در بین کسانی است که حمله قلبی را تجربه نکرده اند.

در مقابل، گروه «بله، حمله قلبی» میانگین سنی ۵۲ سال دارد و ضریب هوشی آن از ۴۴.۵۰ سال تا ۵۹ سال متغیر است. محدوده سنی از ۲۹ سال تا ۷۶ سال متغیر است و میانگین سنی آن ۵۲.۶۵ سال است که با ضربدر مشخص شده است. این گروه هیچ داده پرت قابل توجهی ندارد که نشان دهنده توزیع سنی سازگارتر در مقایسه با گروه «بدون حمله قلبی» است. به طور کلی، داده ها نشان می دهند که افراد بدون حمله قلبی به طور متوسط مسن تر هستند و در مقایسه با افرادی که حمله قلبی را تجربه کرده اند، که عموماً توزیع سنی جوان تر و سازگارتری دارند، محدوده سنی وسیع تری دارند.

نمودار جعبه ای دوم از (شکل ۱) شکل ۱۰ (شکل ۱) فشار خون استراحت (RestBP) را برای کلاس های «بدون حمله قلبی» و «بله حمله قلبی» نشان می دهد. برای کلاس «بدون حمله قلبی»، مقدار متوسط فشار خون استراحت ۱۳۰ میلی متر جیوه است و IQR آن از ۱۲۰ میلی متر جیوه تا ۱۴۵ میلی متر جیوه متغیر است. حداقل مقدار ۱۰۰ میلی متر جیوه و حداکثر مقدار ۱۸۰ میلی متر جیوه است و میانگین فشار خون استراحت ۱۳۴.۴۲ میلی متر جیوه است که با علامت ضربدر نشان داده شده است. در مقادیر ۱۹۲ میلی متر جیوه و ۲۰۰ میلی متر جیوه، مقادیر پرت وجود دارد که نشان می دهد تعداد کمی از افراد مقادیر فشار خون استراحت بسیار بالاتری دارند. این نشان دهنده پراکندگی نسبتاً وسیعی از مقادیر فشار خون استراحت در بین افرادی است که حمله قلبی را تجربه نکرده اند.

**شکل ۱.** نمودار جعبه ای که توزیع سن و فشار خون در حالت استراحت را در مجموعه داده ها نشان می دهد.

کلاس «بله حمله قلبی» دارای مقدار متوسط فشار خون استراحت ۱۳۰ میلی متر جیوه و IQR از ۱۲۰ تا ۱۴۰ میلی متر جیوه است. این مقادیر از ۹۴ میلی متر جیوه تا ۱۷۰ میلی متر جیوه متغیر هستند و میانگین فشار خون استراحت ۱۲۹.۱۷ میلی متر جیوه است که با ضربدر مشخص شده است. مقادیر پرت در این کلاس ۱۷۲ میلی متر جیوه و ۱۷۸ میلی متر جیوه مشاهده می شود. این نشان می دهد که افراد در گروه حمله قلبی عموماً مقادیر فشار خون در حالت استراحت مشابهی دارند و در مقایسه با گروه «بدون حمله قلبی» مقادیر پرت کمتری دارند. به طور کلی، داده ها نشان می دهند که افراد بدون حمله قلبی در مقایسه با افرادی که حمله قلبی را تجربه کرده اند، معمولاً مقادیر فشار خون در حالت استراحت کمی بالاتر و متغیرتری دارند که عموماً دامنه مقادیر ثابت تری با برخی مقادیر پرت بسیار بالا دارند.

اولین نمودار جعبه ای از (شکل ۲) سطح «کلسترول» را برای کلاس های «بدون حمله قلبی» (آبی) و «بله حمله قلبی» نشان می دهد. برای کلاس «بدون حمله قلبی»، میانگین سطح کلسترول ۲۴۹ میلی گرم در دسی لیتر است، با IQR از ۲۱۶.۵ تا ۲۸۳.۵ میلی گرم در دسی لیتر و ۲۸۳.۵ میلی گرم در دسی لیتر. حداقل مقدار ۱۳۱ میلی گرم در دسی لیتر و حداکثر مقدار ۳۵۳ میلی گرم در دسی لیتر است. با میانگین سطح کلسترول ۲۵۱.۱۲ میلی گرم در دسی لیتر، همانطور که با علامت ضربدر نشان داده شده است. یک مقدار پرت در ۴۰۷ میلی گرم در دسی لیتر وجود دارد که نشان می دهد تعداد کمی از افراد مقادیر کلسترول بسیار بالاتری دارند. این نشان دهنده سطح کلسترول نسبتاً گسترده ای در بین کسانی است که حمله قلبی را تجربه نکرده اند.

**شکل ۲.** نمودار جعبه ای که کلسترول و حداکثر ضربان قلب را در مجموعه داده ها نشان می دهد.

کلاس «بله، حمله قلبی» دارای سطح کلسترول متوسط ۲۳۵ میلی گرم در دسی لیتر است و IQR آن از ۲۰۸.۵۰ تا ۲۶۸.۵۰ میلی گرم در دسی لیتر است. مقادیر از ۱۲۶ میلی گرم در دسی لیتر تا ۳۵۴ میلی گرم در دسی لیتر متغیر است و میانگین سطح کلسترول ۲۴۳.۳۲ میلی گرم در دسی لیتر است که با ضربدر مشخص شده است. مقادیر پرت در این کلاس در ۳۶۰ میلی گرم در دسی لیتر، ۳۹۴ میلی گرم در دسی لیتر، ۴۱۷ میلی گرم در دسی لیتر و مقدار قابل توجهی بالا در ۵۶۴ میلی گرم در دسی لیتر مشاهده می شود. این نشان می دهد که افراد در گروه حمله قلبی عموماً به طور متوسط سطح کلسترول پایین تری دارند، اگرچه تعداد کمی با مقادیر قابل توجهی بالاتر وجود دارد. به طور کلی، داده ها نشان می دهند که افراد بدون حمله قلبی در مقایسه با افرادی که حمله قلبی را تجربه کرده اند، معمولاً مقادیر کلسترول بالاتر و پایدارتری دارند که عموماً مقادیر پایین تری با برخی از مقادیر پرت بسیار بالا دارند.

نمودار جعبه ای دوم از (شکل ۲) نشان دهنده "حداکثر ضربان قلب" برای کلاس های "بدون حمله قلبی" و "بله حمله قلبی" است. برای کلاس "بدون حمله قلبی"، میانه مقدار MaxHR برابر با ۱۴۲ ضربه در دقیقه است، با IQR از ۱۲۵ ضربه در دقیقه تا ۱۵۶.۵۰ ضربه در دقیقه. حداقل مقدار ۸۸ ضربه در دقیقه و حداکثر مقدار ۱۹۵ ضربه در دقیقه است، با میانگین MaxHR برابر با ۱۳۹.۰۷ ضربه در دقیقه که با علامت ضربدر نشان داده شده است. یک مقدار پرت در ۷۱ ضربه در دقیقه وجود دارد، که نشان می دهد تعداد کمی از افراد مقادیر MaxHR بسیار پایین تری دارند. این نشان دهنده مقادیر MaxHR نسبتاً گسترده در بین افرادی است که حمله قلبی را تجربه نکرده اند. به طور متفاوت، کلاس "بله حمله قلبی" میانه بالاتری از MaxHR برابر با ۱۶۱ ضربه در دقیقه دارد، با IQR از ۱۴۸.۵۰ ضربه در دقیقه تا ۱۷۲ ضربه در دقیقه. مقادیر از ۱۱۴ ضربه در دقیقه تا ۲۰۲ ضربه در دقیقه متغیر است، با میانگین MaxHR برابر با ۱۵۸.۳۱ ضربه در دقیقه، که با علامت ضربدر مشخص شده است. موارد پرت در این دسته در ۹۶ ضربه در دقیقه، ۱۰۵ ضربه در دقیقه و ۱۱۱ ضربه در دقیقه مشاهده می شوند. این نشان می دهد که افراد در گروه حمله قلبی عموماً مقادیر MaxHR بالاتری دارند، اگرچه تعداد کمی با مقادیر به طور قابل توجهی پایین تر وجود دارند. به طور کلی، داده ها نشان می دهند که افراد بدون حمله قلبی در مقایسه با افرادی که حمله قلبی را تجربه کرده اند، مقادیر MaxHR پایین تری دارند که عموماً مقادیر بالاتری با برخی از موارد پرت قابل توجه دارند.

اولین نمودار جعبه ای از (شکل ۳) مربوط به "STdp" برای کلاس های "بدون حمله قلبی" و "بله حمله قلبی" است. برای کلاس "بدون حمله قلبی"، مقدار میانه افت ST برابر با ۱.۴۰ است، با IQR از ۰.۶۰ تا ۲.۵۵. مقادیر از ۰.۰۰ تا ۴.۴۰ متغیر است، با میانگین افت ST در ۱.۶۰ که با علامت ضربدر نشان داده شده است. موارد پرت قابل توجه در ۵.۶۰ و ۶.۲۰ وجود دارند، که نشان دهنده تعداد کمی از افراد با مقادیر افت ST به طور قابل توجهی بالاتر است. این نشان دهنده مقادیر نسبتاً گسترده افت ST در بین افرادی است که حمله قلبی را تجربه نکرده اند. کلاس "بله حمله قلبی" دارای مقدار میانه افت ST پایین تر از ۰.۰۰، با IQR از ۰.۰۰ تا ۱.۱۰ است. مقادیر از ۰.۰۰ تا ۲.۶۰ متغیر است، با میانگین افت ST در ۰.۶۰، که با علامت ضربدر مشخص شده است. موارد پرت در این کلاس در ۳.۰۰، ۳.۵۰ و ۴.۲۰ مشاهده می شوند. این نشان می دهد که در حالی که اکثر افراد در گروه حمله قلبی مقادیر پایین افسردگی ST دارند، تعداد کمی از آنها مقادیر بسیار بالاتری دارند. به طور کلی، داده ها نشان می دهند که افراد بدون حمله قلبی، در مقایسه با افرادی که حمله قلبی را تجربه کرده اند، تمایل به داشتن مقادیر افسردگی ST بالاتر و متغیرتری دارند، که عموماً مقادیر پایین تری با برخی از داده های پرت قابل توجه دارند.

**شکل ۳.** نمودار جعبه ای که میزان افت قطعه ST ناشی از ورزش را نسبت به حالت استراحت و تعداد رگ های اصلی در مجموعه داده ها نشان می دهد.

در نهایت، نمودار جعبه ای دوم از (شکل ۳) تعداد رگ های اصلی را برای کلاس های «بدون حمله قلبی» و «بله حمله قلبی» نشان می دهد. برای کلاس «بدون حمله قلبی»، میانه تعداد رگ های اصلی ۰ است، با IQR از ۰ تا ۲. حداقل مقدار ۰ و حداکثر مقدار سه رگ اصلی است. میانگین تعداد رگ های اصلی، همانطور که با علامت ضربدر نشان داده شده است، ۱.۱۵ است. هیچ داده پرتی در این کلاس وجود ندارد، که نشان می دهد داده هادر محدوده مشاهده شده نسبتاً سازگار هستند. در مقابل، کلاس «بله حمله قلبی» میانه ۰ رگ اصلی و IQR را نشان می دهد که از ۰ تا ۰ را نیز در بر می گیرد، که نشان می دهد هیچ پراکندگی در مقادیر مرکزی وجود ندارد. حداقل و حداکثر مقادیر هر دو ۰ رگ اصلی هستند. میانگین تعداد رگ های اصلی ۰.۲۷ است، همانطور که با علامت ضربدر نشان داده شده است. با این حال، در یک، دو و سه رگ اصلی، داده های پرت وجود دارد، که نشان می دهد برخی از افراد در این کلاس رگ های اصلی بیشتری دارند، اما توزیع کلی ...



متمركز بر مقادير پايين تر. اين شكل نشان مي دهد كه حمله انفرادي عموماً در مقايسه با حمله هاي ديگر، كشتي هاي اصلي كمترى داشته است. گروهى كه طيف وسيع تر و بالاترى از مقادير را نشان مي دهد.


### ۳.۱.۲ تحليل مجموعه داده هاي حمله قلبى

هدف اين زيربخش ارائه تحليلي جامع از رابطه با كلاس هدف است. اين زيربخش توزيع و پتانسيل [موارد/موارد/موارد/...] را بررسي خواهد كرد. بابرسته كردن ميزان شيوع آنها در هر ايالت از هدف، با در نظر گرفتن اين جنبه ها، مي توانيم الگ. با بررسي بينش عميق ترى در مورد چگونگى تأثير ويژگى هاي اسمى بر يكدیگر به دست آوريم. و تصميم گيرى و مدل سازى پيش بينى مؤثرترى را ارائه مي دهد.

### شيوع حمله قلبى بر اساس جنسيت

شكل ۴ توزيع وقوع حمله قلبى را نشان مي دهد. بين جنسيت ها، اين نشان مي دهد كه ۲۴ زن و ۱۱۳ مرد حمله قلبى را تجربه نكرده اند و ۸۹ مرد حمله قلبى رگ. در حالى كه ۷۲ زن تجربه كرده اند. اين مقايسه، وقوع حمله قلبى بين بيماران مرد و زن را بررسته مي كند. تفاوت هارا نشان مي دهند. در اين نمونه، مردان تعداد كلى موارد حمله قلبى بيشترى دارند.

تفاوت بين جنسيت ها ممكن است تحت تأثير عوامل مختلفى باشد. در سبك زندگى، زمينه هاي ژنتيكي، تأثيرات هورموني و دسترسى به مراقبت هاي بهداشتى. مردان ممكن است به دليل شيوع بيشتر عوامل خطر خاص مانند سيگار كشيدن، در معرض خطر بيشترى باشند. و فشار خون بالا [۲۷].




شكل ۴. شيوع حمله قلبى در بين مردان (مذكر) و زنان (مونث) (جنسيت) در مجموعه داده ها er

با اين حال، مهم است كه در نظر داشته باشيد كه زنان ممكن است تومورهاي خوش خيم را به علائم حمله قلبى طور متفاوتى تجربه كنند، كه مي تواند منجر به تشخيص نادرست يا عدم تشخيص شود. زنان بيشتر هستند احتمالاً علائم غير معمولى مانند حالت تهوع يا خستگى به جاي درد قفسه سينه كلاسيك كه اغلب در مردان ديده مى شود، وجود دارد. اين مي تواند منجر به تاخير در مراجعه به پزشك شود و به طور بالقوه بر نتايج تأثير بگذارد. بنابراين، آگاهى و آموزش در مورد علائم خاص جنسيتى در بهبود تشخيص و درمان حملات قلبى در مردان و زنان بسيار مهم است.

### شيوع حمله قلبى بر اساس نوع درد قفسه سينه

شكل ۵ اين مطالعه بينش هايى در مورد چگونگى ارتباط انواع مختلف درد قفسه سينه با وقوع حملات قلبى ارائه مي دهد. اين مطالعه نشان مي دهد كه در بين افرادى كه حملات قلبى را تجربه كرده اند، افراد مبتلا به آنژين معمولى و غير معمولى به طور قابل توجهى شايع تر بوده اند. به طور خاص، ۶۶ مورد شامل آنژين غير معمولى و ۴۰ مورد شامل آنژين معمولى بودند كه اين موارد را به عنوان شاخص هاي كليدى خطر حمله قلبى بررسته مي كند. در مقابل، حملات قلبى كمترى در بين افراد مبتلا به درد غير آنژيني و افراد بدون علامت مشاهده شد كه نشان مي دهد اين نوع درد قفسه سينه كمتر پيش بينى كننده حملات قلبى است.

حمله قلبی در مقابل نوع درد قفسه سینه



شکل ۵. شیوع حمله قلبی به ازای هر نوع درد قفسه سینه در مجموعه داده ها.

### شیوع حمله قلبی بر اساس قند خون ناشتا

علاوه بر این، نمودار میله ای در شکل ۶ رابطه بین متغیر اسمی FastBS (که نشان می دهد آیا قند خون ناشتا بالاتر از ۱۲۰ میلی گرم در دسی لیتر است) و وقوع حملات قلبی. این نشان می دهد که در بین افراد wi (یعنی برابر با بله)، تعداد ارتقایافته FastBS موارد حمله قلبی (۲۳ نفر) برابر با تعداد موارد غیر حمله قلبی (۲۱ نفر) است. در مقابل، تقریباً برابر با در بین برابر با خیر، افراد بیشتری با حمله قلبی (۱۳۸ نفر در مقابل ۱۱۶ نفر بدون حمله قلبی) در مقایسه با ۱۳۸ نفر در مقابل ۱۱۶ نفر بدون حمله قلبی وجود دارند که تفاوت قابل توجهی را برجسته می کند. بروز مرتبط با سطح قند خون ناشتا.

حمله قلبی در مقابل قند خون ناشتا




شکل ۶. شیوع حمله قلبی به ازای مقدار قند خون ناشتا در مجموعه داده ها.

### شیوع حمله قلبی بر اساس آنژین ناشی از ورزش

تمرکز روی شکل ۷ تا جایی که به شیوع حمله قلبی در بین افرادی که آنژین ناشی از ورزش نداشتند مربوط می شود، ۱۳۸ نفر از ۲۰۰ نفر (۶۹٪) دچار حمله قلبی شدند. در بین افرادی که آنژین ناشی از ورزش داشتند، ۲۳ نفر از ۹۸ نفر (۲۳.۴۷٪) دچار حمله قلبی شدند. مشاهده شده است که درصد قابل توجهی بالاتر از افرادی که آنژین ناشی از ورزش نداشتند، در مقایسه با افرادی که آنژین ناشی از ورزش داشتند، دچار حمله قلبی شدند. این می تواند نشان دهد که وجود آنژین ناشی از ورزش ممکن است یک عامل محافظتی باشد یا اینکه افراد بدون آن به دلیل سایر عوامل زمینه ای در معرض خطر بیشتری هستند.

## حمله قلبی در مقابل آنژین ناشی از ورزش



مجموعه داده ها.

شکل ۷. شیوع حمله قلبی به ازای هر نوع آنژین ناشی از ورزش در ...

## شیوع حمله قلبی بر اساس نوار قلب در حالت استراحت


شکل ۸ نشان می دهد که چگونه شیوع حمله قلبی در بین افراد با نتایج ECG در حالت استراحت متفاوت است. افرادی که نتایج ECG در حالت استراحت طبیعی دارند، میزان بالایی را نشان می دهند. شیوع حملات قلبی، با ۶۲.۱۶٪ تجربه حمله قلبی. بخش قابل توجهی از افراد با نتایج نوار قلب طبیعی هنوز در انتظار هستند که نیاز به ارزیابی ریسک جامع فراتر از نوار قلب را برجسته می کند.

افرادی که در نوار قلب در حالت استراحت خود هیپرتروفی دارند، شیوع کمتری از سرطان سینه دارند. برای کسانی که نتایج نوار قلب طبیعی دارند، با ۴۶.۵۸٪ تجربه حمله قلبی، اگرچه هیپرتروفی با حملات قلبی مرتبط است، اما ممکن است ... همانطور که در ابتدا تصور می شد، یا عوامل دیگری ممکن است بر این خطر تأثیر بگذارند.

ناهنجاری های فردی در نوار قلب در حالت استراحت آنها کمترین شیوع سرطان را نشان می دهد. ۲۵٪ دچار حمله قلبی می شوند. با وجود حجم نمونه کوچک، این ناهنجاری های موج T نشان می دهد که ST به تنهایی ممکن است پیش بینی کننده قوی برای مشکلات قلبی نباشد.

داده هانشان می دهند افرادی که نتایج ECG طبیعی و هیپرتانسیون دارند، در مقایسه با افرادی که موج ST-T غیرطبیعی دارند، در معرض خطر حملات قلبی هستند.

## حمله قلبی در مقابل نوار قلب در حالت استراحت




شکل ۸. شیوع حمله قلبی به ازای هر مقدار ECG در حالت استراحت در مجموعه داده ها.

### شیوع حمله قلبی بر حسب شیب

شکل ۹ این نشان دهنده تنوع واضحی در شیوع حمله قلبی در انواع مختلف است. نتایج ECG با شیب صعودی به شدت با خطر بالای ... مرتبط هستند. نتایج شیب نزولی و شیب مسطح، همبستگی متوسط و پایینی را نشان می دهند.

شیب ECG روی sed  
حملات قلبی، در حالی که  
به ترتیب.

حمله قلبی در مقابل شیب دار



شکل ۹. شیوع حمله قلبی به ازای هر نوع شیب دار در مجموعه داده ها.

افرادی که نتایج نوار قلبشان شیب نزولی دارد، شیوع حمله قلبی ۴۲.۸۶٪ دارند. اکثر (۵۷.۱۴٪) افرادی که شیب نزولی دارند، حمله قلبی را تجربه نمی کنند، که نشان دهنده ارتباط متوسط با خطر حمله قلبی است.

افرادی که نتایج نوار قلب آنها با شیب صاف نشان می دهد، شیوع حمله قلبی ۳۴.۷۸٪ است. بخش قابل توجهی (۶۵.۲۲٪) از افراد با شیب صاف، حمله قلبی را تجربه نمی کنند، که نشان می دهد شیب صاف در مقایسه با سایر انواع شیب، ارتباط کمتری با خطر حمله قلبی دارد.


افرادی که نتایج نوار قلب آنها رو به بالا است، بیشترین شیوع حملات قلبی را دارند و ۷۴.۸۲٪ از آنها دچار حمله قلبی شده اند. این نشان دهنده ارتباط قوی بین نتایج نوار قلب رو به بالا و خطر حمله قلبی است و این افراد در معرض بیشترین خطر ابتلا به حملات قلبی هستند که اهمیت شناسایی و نظارت دقیق بر این افراد را برجسته می کند. نتایج نوار قلب رو به پایین و با شیب صاف با خطرات کمتر حمله قلبی مرتبط هستند، اما همچنان به ویژه در حضور سایر عوامل خطر، توجه را می طلبد.

بررسی مکانیسم های اساسی که در شیوع متفاوت حمله قلبی در بین انواع مختلف شیب بندی نقش دارند، می تواند منجر به بهبود مدل های پیش بینی و استراتژی های درمانی شود.

### شیوع حمله قلبی در بیماران تالاسمی

شکل مشاهده ۱۰ افراد مبتلا به تالاسمی طبیعی بیشترین شیوع حمله قلبی را دارند، به طوری که ۷۷.۵۸٪ از افراد دچار حمله قلبی می شوند. این نشان دهنده ارتباط قوی بین تالاسمی طبیعی و وقوع حملات قلبی است. شیوع بالای حملات قلبی در بین افراد مبتلا به تالاسمی طبیعی، نیاز به ارزیابی و مدیریت دقیق خطر قلبی عروقی در این گروه را برجسته می کند. نظارت منظم و اقدامات پیشگیرانه ممکن است برای افراد مبتلا به تالاسمی طبیعی برای کاهش خطر حمله قلبی بسیار مهم باشد.

شیوع حمله قلبی در افراد مبتلا به تالاسمی با نقص ثابت ۳۳.۳۳ درصد است که کمتر از تالاسمی معمولی اما بالاتر از تالاسمی با نقص برگشت پذیر است. این نشان می دهد که نقص های ثابت ارتباط متوسطی با حملات قلبی دارند و در دسته خطر متوسط قرار می گیرند، که نشان می دهد آنها نیاز به یک رویکرد متعادل از نظر نظارت و مراقبت های پیشگیرانه دارند.



شکل ۱۰. شیوع حمله قلبی به ازای هر نوع تالاسمی در مجموعه داده ها.

افراد مبتلا به تالاسمی با نقص برگشت پذیر، شیوع حملات قلبی بسیار کمتری دارند و تنها ۲۳.۴۸٪ از آنها دچار حمله قلبی می شوند. این نشان می دهد که آنها در مقایسه با تالاسمی معمولی، ممکن است کمتر با حملات قلبی مرتبط باشند. شیوع کمتر حملات قلبی در افراد مبتلا به تالاسمی با نقص برگشت پذیر نشان می دهد که ممکن است عوامل محافظتی مرتبط با نقص های برگشت پذیر وجود داشته باشد. درک این عوامل می تواند در تدوین استراتژی هایی برای کاهش خطرات حمله قلبی در سایر بیماری های تالاسمی مفید باشد.

به عنوان خلاصه ای از تجزیه و تحلیل ویژگی های فوق، اگرچه مجموعه داده ها بینش های اولیه ای در مورد تفاوت های بین ویژگی های بروز حمله قلبی ارائه دادند (به عنوان مثال، تفاوت های جنسیتی با تعداد کلی بالاتر موارد حمله قلبی در بین مردان در مقایسه با زنان)، اما اندازه نمونه برای تعمیم نتیجه گیری های ما محدود بود. تعامل پیچیده بین عوامل متعدد، مانند سن، سطح کلسترول و نوع درد قفسه سینه، و نحوه تأثیر آنها بر خطر حمله قلبی، نیز مشهود است اما نیاز به بررسی بیشتر دارد. با توجه به این محدودیت، مطالعات آینده با نمونه های بزرگتر و متنوع تر برای درک کامل سوگیری های بالقوه و همبستگی های ویژه و تأیید هرگونه تفاوت مشاهده شده (به عنوان مثال، مبتنی بر جنسیت) مورد نیاز است. تجزیه و تحلیل دقیق تر از نحوه تعامل این عوامل با یکدیگر می تواند عمق قابل توجهی به درک ما از خطرات حمله قلبی بیفزاید و محور تحقیقات آینده خواهد بود.

### ۳.۲ روش شناسی

تحلیل جامع ویژگی های عددی در بخش ۳.۱ بینش هایی در مورد داده های پرت و لزوم نرمال سازی، به ویژه در اطمینان از اینکه توزیع های کج به درستی مقیاس بندی شده اند تا از سوگیری مدل جلوگیری شود، ارائه داد. این رویکرد در تضاد با سایر مطالعات است [۱۴، ۱۵، ۱۷-۲۲] که یا از تحلیل توزیع قبل از پیش پردازش غفلت کرده یا تأکید کمتری بر آن داشته اند. یافته های ما بر اهمیت بررسی دقیق آمار ویژگی ها و توزیع ها تأکید می کند و نشان می دهد که چنین بررسی دقیقی برای بهینه سازی عملکرد مدل، به ویژه هنگام کار با مجموعه داده های کوچک تا متوسط، ضروری است. روش شناسی کاربردی شامل وظایف زیر است:

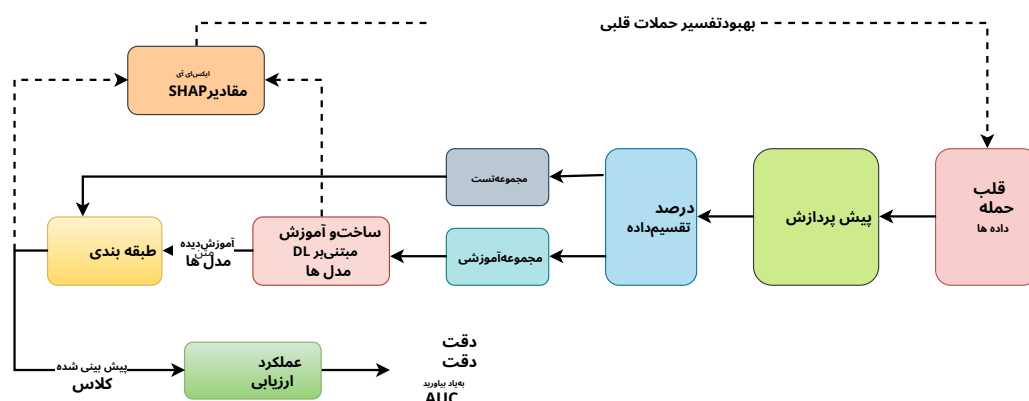
- اولین گام در پیش پردازش داده ها، بررسی ستون های ویژگی با مقادیر گمشده و ردیف های تکراری بود. مشاهده شد که ۶ مورد از ۳۰۳ رکورد موجود در مجموعه داده ها، یک ویژگی با مقدار خالی داشتند. در چارچوب مطالعه حاضر، ما تصمیم گرفتیم این رکوردها را حذف کنیم و هیچ روش جانشینی داده ای (مثلاً با مقدار میانگین ویژگی عددی یا حالت ویژگی دسته بندی) اعمال نکنیم. علاوه بر این، هیچ ردیف تکراری وجود نداشت.

- سپس متغیرهای دسته بندی شده با استفاده از کدگذاری وان-هات کدگذاری شدند تا به فرمتی مناسب برای الگوریتم های یادگیری ماشین تبدیل شوند. این فرآیند شامل ایجاد

ستون‌های دودویی برای هر دسته در یک ویژگی دسته بندی شده، که تضمین می کند مدل ها می توانند این اطلاعات را به طور مؤثر تفسیر و استفاده کنند.

- ویژگی های عددی با استفاده از مقیاس بندی حداقل-حداکثر نرمال سازی شدند تا همه ویژگی ها در محدوده یکسانی [0، 1] قرار گیرند، که به تسریع همگرایی الگوریتم های بهینه سازی مبتنی بر گرادیان مورد استفاده در آموزش مدل ها کمک می کند.

شکل ۱۱ یک گردش کار جامع برای توسعه و ارزیابی مدل های DL برای پیش بینی حمله قلبی را نشان می دهد. این کار با جمع آوری و پیش پردازش داده های حمله قلبی آغاز می شود و پس از آن مجموعه داده ها به مجموعه های آموزشی و آزمایشی تقسیم می شوند. سپس مدل های مختلف DL با استفاده از داده های آموزشی ساخته و آموزش داده می شوند. عملکرد این مدل ها در مجموعه آزمایشی با استفاده از معیارهایی مانند دقت، صحت، فراخوانی و AUC ارزیابی می شود. برای افزایش قابلیت تفسیر، از یک تکنیک XAI برای تفسیر درک پیش بینی های انجام شده توسط مدل های DL استفاده شد. روش اصلی مورد استفاده در این مطالعه SHAP بود. این تکنیک برای شفاف و قابل تفسیر کردن پیش بینی های مدل های پیچیده (به عنوان مثال، مدل های DL) به ویژه در زمینه های حیاتی مانند مراقبت های بهداشتی بسیار مهم است. مقادیر SHAP برای درک تأثیر ویژگی های مختلف بر پیش بینی های مدل محاسبه می شوند. یک حلقه بازخورد با ارائه بینش های به دست آمده از ارزیابی و تجزیه و تحلیل SHAP به بلوک داده اولیه برای جمع آوری، بهبود و آموزش مجدد مدل، امکان بهبود مستمر را فراهم می کند. این فرآیند تکراری، توسعه مدل های قوی و قابل تفسیر برای پیش بینی حمله قلبی را تضمین می کند.



شکل ۱۱. گردش کار برای پیش بینی حمله قلبی با استفاده از یادگیری ماشینی (DL)، شامل پیش پردازش، آموزش مدل، ارزیابی، تفسیر SHAP و بهبود تکراری.

مقادیر SHAP با پیوند دادن نظریه بازی ها با توضیحات محلی، معیاری یکپارچه از اهمیت ویژگی ها ارائه می دهند. روش SHAP به هر ویژگی، یک مقدار اهمیت برای یک پیش بینی خاص اختصاص می دهد. اساس مقادیر SHAP بر اساس مقادیر Shapley از نظریه بازی های مشارکتی است که «پرداخت» را به طور منصفانه بین ویژگی ها (یا بازیکنان) بر اساس سهم آنها در پیش بینی توزیع می کند. برای یک مدل و یک نمونه خاص/یکس، مقدار SHAP  $\phi$  من برای ویژگی من به صورت زیر محاسبه می شود:

$$\phi = \sum_{S \subseteq N, i \in S} \frac{1}{|S|!} \frac{(|N|-|S|)!}{|N|!} \frac{f(S \cup \{i\}) - f(S)}{|N|}$$

کجا N مجموعه ای از تمام ویژگی ها است، S زیرمجموعه ای از است N فاقد ویژگی من، |S|/|N| است تعداد عناصر در زیرمجموعه S، و f(S) یکس (س) برای مثال، پیش بینی مدل است یکس فقط با ویژگی های موجود در زیرمجموعه S اصطلاح |S|/|N| نشان دهنده وزن سهم است از زیرمجموعه ویژگی ها S در ائتلاف. این معادله تضمین می کند که سهم هر ویژگی در تمام ائتلاف های ممکن به طور منصفانه وزن دهی شده باشد و مقادیر SHAP را سازگار و قابل تفسیر کند.

در عمل، محاسبه مقادیر SHAP مستقیماً از معادله می تواند از نظر محاسباتی پرهزینه باشد. بنابراین، اغلب از روش های تقریبی مانند Kernel SHAP استفاده می شود. رابا استفاده از رگرسیون خطی وزنی در یک ویژگی تبدیل شده تخمین می زند SHAP مقادیر SHAP.



فضا، که اعمال آن را به مدل های پیچیده امکان پذیر می کند. در این مطالعه، مقادیر SHAP برای هر مدل محاسبه شد تا تأثیر هر ویژگی بر نتیجه پیش بینی شده کمی سازی شود.

### ۳.۳ مدل های یادگیری عمیق

در این مطالعه، ما از مدل های مختلف یادگیری عمیق (DL) برای پیش بینی خطر حمله قلبی بر اساس داده های بیمار استفاده کردیم. این مدل ها شامل LSTM، GRU، RNN، MLP و یک مدل ترکیبی با ترکیب ویژگی های CNN و RNN بودند.

انتخاب مدل های DL برای این مطالعه به دلیل توانایی اثبات شده ی آن ها در پردازش و تجزیه و تحلیل کارآمد داده های پیچیده و با ابعاد بالا که معمولاً در مجموعه داده های پزشکی وجود دارد، صورت گرفته است. شبکه های عصبی کانولوشن (CNN) به دلیل توانایی استثنایی شان در استخراج ویژگی های مکانی انتخاب شدند که آن ها را برای داده های تصویربرداری پزشکی ایده آل می کند. با این حال، در این مطالعه، آن ها برای استفاده با داده های جدولی به کار گرفته شدند. شبکه های عصبی بازگشتی (RNN)، همراه با شبکه های LSTM و GRU، به دلیل عملکرد قوی شان در مدیریت داده های ترتیبی انتخاب شدند که برای ثبت الگوهای زمانی در تاریخچه ی بیماران بسیار مهم هستند.

مدل ترکیبی (Hybrid) به صورت استراتژیک برای ترکیب نقاط قوت CNN ها و GRU ها طراحی شده است، با هدف افزایش دقت پیش بینی با ادغام قابلیت های پردازش داده های مکانی و زمانی برای رفع محدودیت های مدل های دیگر که در آن ها این ویژگی ها به طور ناکافی ثبت شده اند. ترکیب CNN و GRU در یک مدل پیش بینی حمله قلبی، امکان ثبت مؤثر ویژگی های مکانی و زمانی را در مجموعه داده ها فراهم می کند. مؤلفه CNN در تشخیص روابط مکانی پیچیده بین ویژگی های بیمار، مانند سن، سطح کلسترول و فشارخون، که شاخص های حیاتی خطر حمله قلبی هستند، عالی عمل می کند. در همین حال، مؤلفه GRU می تواند جنبه های زمانی را نیز مدیریت کند و به طور مؤثر نحوه تغییر این ویژگی ها در طول زمان، مانند نوسانات فشار خون یا ضربان قلب را تجزیه و تحلیل کند. با ادغام این جنبه ها، مدل ترکیبی CNN-GRU می تواند پیش بینی جامع تر و دقیق تری از حملات قلبی ارائه دهد و بیماران در معرض خطر را با در نظر گرفتن وضعیت سلامت فعلی و پیشرفت سلامت آن ها در طول زمان شناسایی کند.

پاراگراف های زیر خلاصه ای از عملکرد و ویژگی های اصلی هر مدل را ارائه می دهند.

- **MLP [۲۸]** یک معماری شبکه عصبی پیش خور است. این شبکه از یک لایه ورودی، چندین لایه پنهان و یک لایه خروجی تشکیل شده است. هر نورون در یک لایه از طریق اتصالات وزن دار به هر نورون در لایه بعدی متصل است. خروجی هر نورون، مجموع وزن دار ورودی های آن است که با یک فعال سازی غیرخطی دنبال می شود.

تابع از نظر ریاضی، فعال سازی  $f(x)$  (۱+)

$$f(x) = \sum_{j=1}^n w_j x_j + b$$

کجا  $f$  (بی فعال شدن نورون است)  $w_j$  (دلیوی) نورون متصل کننده وزن است

جی در لایه به نورون من در لایه  $1 + b$ ، سوگیری نورون است من در لایه  $1 +$ ، و تابع فعال سازی است که معمولاً ReLU (واحد خطی یکسو شده) نامیده می شود و به صورت زیر تعریف می شود.  $f(x) = \max(0, x)$  (یکس) حداکثر  $0$ ، یکس فرآیند یادگیری شامل تنظیم وزن ها و بایاس ها برای به حداقل رساندن تابع زیان است که اغلب از پس انتشار و گرادیان نزولی استفاده می کند.

- **سی ان ها [۲۹]** برای پردازش داده هایی با توپولوژی شبکه ای مانند، مانند تصاویر، تخصص یافته اند. عملیات اصلی در یک CNN، کانولوشن است که مجموعه ای از فیلترهای قابل یادگیری را برای استخراج الگوهای محلی به ورودی اعمال می کند. عملیات کانولوشن برای یک ورودی/یکس با فیلترک به صورت زیر تعریف می شود

$$Z_{m,n} = \sum_{k=0}^{M-1} \sum_{l=0}^{N-1} I_{k,l} * W_{k,l} + b_m$$

کجا (من، جی) مختصات مکانی هستند، و  $M \times N$  اندازه فیلتر است. سپس خروجی از یک تابع فعال سازی غیرخطی عبور داده می شود. لایه های Pooling، مانند max pooling،

ابعاد مکانی را کاهش می دهد در حالی که برجسته ترین ویژگی ها را حفظ می کند. نقشه های ویژگی نهایی مسطح شده و برای طبقه بندی به لایه های کاملاً متصل تغذیه می شوند.

• **شبکه های عصبی بازگشتی (RNN) [۳۰]** برای داده های ترتیبی با حفظ یک حالت پنهان که اطلاعات مربوط به ورودی های قبلی را ثبت می کند، طراحی شده اند. حالت پنهان در گام زمانی به صورت زیر محاسبه می شود

$$ح_ت = f(دلیو ح_ت-۱ + دلیو ایکس_ت + ب) ،$$

کجا ایکس\_ت ورودی در گام زمانی است، ح\_ت-۱ حالت پنهان از گام زمانی قبلی است، دلیو ح و دلیو ایکس ماتریس های وزنی هستند، ب بردار بایاس است، و ف تابع فعال سازی است که معمولاً  $\tanh$  است. این فرآیند بازگشتی به RNN اجازه می دهد تا وابستگی های زمانی را در داده های توالی ثبت کند.

• **LSTM [۳۱]** شبکه های LSTM نوعی از RNN هستند که با استفاده از مکانیسم های گیتینگ، مشکل گرادیان صفرشونده را کاهش می دهند. یک سلول LSTM شامل یک گیت ورودی است، من\_ت، دروازه فراموشی ف\_ت، یک گیت خروجی ا\_ت و یک حالت سلولی سی\_ت، به شرح زیر:

$$(1) \quad \begin{aligned} \text{من}_ت &= \text{سیگما}(دلیو \text{من}_ت + \text{ایو} \text{من}_ت + \text{ب}_\text{من}) \quad \text{ف} \\ \text{ف}_ت &= \text{سیگما}(دلیو \text{ف}_ت + \text{ایو} \text{ف}_ت + \text{ب}_\text{ف}) \\ \text{ای}_ت &= \text{سیگما}(دلیو \text{ای}_ت + \text{ایو} \text{ای}_ت + \text{ب}_\text{ای}) \quad \text{سی}_ت = \\ \text{تان}(دلیو \text{سی}_ت + \text{ایو} \text{سی}_ت + \text{ب}_\text{سی}) \quad \text{سی}_ت &= \text{ف}_ت \odot \text{سی}_ت \\ \text{سی}_ت &= \text{من}_ت + \text{ای}_ت \odot \text{سی}_ت \\ \text{ح}_ت &= \text{ای}_ت \odot \text{تان}(\text{سی}_ت) \end{aligned}$$

کجا سیگما تابع سیگموئید است و  $\odot$  نشان دهنده ضرب عنصر به عنصر است. این گیت ها جریان اطلاعات را کنترل می کنند و شبکه را قادر می سازند تا در صورت نیاز اطلاعات را حفظ یا حذف کند.

• **جی آر یو [۳۲]** یک نوع ساده شده از LSTM است که گیت های فراموشی و ورودی را در یک گیت به روزرسانی واحد ترکیب می کند. زتی و یک دروازه تنظیم مجدد را معرفی می کند زتی، به شرح زیر:

$$(2) \quad \begin{aligned} \text{زتی} &= \text{سیگما}(دلیو \text{زتی} + \text{ایو} \text{زتی} + \text{ب}_\text{زتی}) \quad \text{رتی} \\ \text{سیگما} &= (دلیو \text{رتی} + \text{ایو} \text{رتی} + \text{ب}_\text{رتی}) \\ \text{من}_ت &= \text{تان}(دلیو \text{ح}_ت + \text{ایو} \text{ح}_ت + \text{ب}_\text{ح}) \\ \text{ح}_ت &= (1 - \text{زتی}) \odot \text{ح}_ت + \text{زتی} \odot \text{من}_ت \end{aligned}$$

معماری GRU مکانیزم گیتینگ را ساده می کند و در عین حال توانایی ثبت وابستگی ها در توالی های طولانی را حفظ می کند.

• **هیبریدی** این مدل نقاط قوت CNN ها و GRU ها را برای بهره برداری مؤثر از ویژگی های مکانی و زمانی ترکیب می کند. این معماری ابتدا شامل استفاده از لایه های CNN برای پردازش داده های ورودی و استخراج ویژگی های مکانی است. سپس این ویژگی ها به لایه های GRU داده می شوند تا وابستگی های زمانی را ثبت کنند. عملیات کانولوشن در لایه های CNN به صورت زیر تعریف می شود:

$$(\text{ایکس} * \text{ک})(\text{من، جی}) = \sum_{\text{متر}=0}^{\text{م}-1} \sum_{\text{ن}=0}^{\text{ن}-1} (\text{ایکس}(\text{من} + \text{متر، جی} + \text{ن}) * \text{ک}(\text{متر، ن}))$$

پس از عبور از لایه های کانولوشن و Pooling، نگاشت های ویژگی خروجی ف به یک بردار یک بعدی مسطح می شوند ف لات، به شرح زیر:

$$\text{ف لات} = \text{صاف کردن}(\text{ف})$$

این بردار مسطح  $\text{فلاف}$  لات سپس تغییر شکل داده می شود تا با فرمت ورودی لایه های GRU مطابقت داشته باشد. اگر  $\text{فلاف}$  لات دارای ابعاد  $(n, \text{سی})$ ، کجان تعداد گام های زمانی است و  $\text{سی}$  تعداد ویژگی ها در هر گام زمانی است که به صورت زیر به لایه GRU وارد می شود:

$$(3) \quad \begin{aligned} \text{زتی} &= \text{سیگما}(\text{دیلیورفلاف لات، تی} + \text{یورجی} - \text{ب} + \text{زتی}) \\ \text{سیگما} &= \text{دیلیورفلاف لات، تی} + \text{یورجی} - \text{ب} + \text{ر} \\ \text{تی} &= \text{تان}(\text{دیلیورفلاف لات، تی} + \text{یورجی} - \text{ر} + \text{تی} - \text{ب} + \text{ح}) \\ \text{ح} &= (1 - \text{زتی}) \times \text{ح} - \text{زتی} + \text{تی} \end{aligned}$$

اینجا،  $\text{فلاف}$  لات، نشان دهنده بردار ویژگی در گام زمانی است، و  $\text{ح}$  حالت پنهان در گام زمانی است. در نهایت، حالت های پنهان از GRU برای طبقه بندی از طریق لایه های کاملاً متصل عبور داده می شوند، به شرح زیر:

$$\text{ی} = \text{سافت مکس}(\text{دیلیوری} - \text{ب} + \text{ی})$$

کجادیلوی ماتریس وزن است،  $\text{ب}$  بردار بایاس لایه کاملاً متصل است، و  $\text{ح}$  حالت پنهان در گام زمانی پایانی است. تابع  $\text{softmax}$ ، لوجیت ها را به احتمالاتی برای هر کلاس تبدیل می کند و امکان طبقه بندی را فراهم می کند. مدل ترکیبی از توانایی CNN ها در استخراج ویژگی های مکانی پیچیده و توانایی GRU در ثبت وابستگی های زمانی بهره می برد که منجر به بهبود عملکرد پیش بینی می شود.

### ۳.۴ معیارهای ارزیابی

اثر بخشی مدل های یادگیری ماشینی (DL) از طریق چندین معیار ضروری، از جمله دقت، صحت، فراخوانی، امتیاز F1 و AUC ارزیابی می شود. این معیارها درک جامعی از اثربخشی مدل در پیش بینی حمله قلبی ارائه می دهند [۳۳].

- **دقت** نسبت نمونه های درست پیش بینی شده در میان تمام نمونه ها است.

تعریف شده به عنوان

$$\text{دقت} = \frac{\text{تی پی} + \text{تنسی}}{\text{تی پی} + \text{تنسی} + \text{ف اف پی} + \text{ان}}$$

کجانی پی تعداد موارد مثبت واقعی (موارد حمله قلبی) است،  $\text{تنسی}$  تعداد موارد منفی واقعی (موارد غیر از حمله قلبی) است،  $\text{ف اف پی}$  تعداد موارد مثبت کاذب (موارد غیر حمله قلبی که به اشتباه به عنوان حمله قلبی طبقه بندی شده اند) است، و  $\text{ان}$  تعداد موارد منفی کاذب (موارد حمله قلبی که به اشتباه به عنوان موارد غیر حمله قلبی طبقه بندی شده اند) است.

- **دقت** که به عنوان ارزش پیش بینی مثبت نیز شناخته می شود، نسبت پیش بینی های مثبت واقعی در بین تمام پیش بینی های مثبت است. این به صورت زیر تعریف می شود.

$$\text{دقت} = \frac{\text{تی پی}}{\text{تی پی} + \text{ف اف پی}}$$

نشان می دهد که چه تعداد از موارد حمله قلبی پیش بینی شده صحیح بوده اند. دقت بالا در جلوگیری از هشدارها یا درمان های غیر ضروری بسیار مهم است.

- **به یاد بیاورید** که به عنوان حساسیت یا نرخ مثبت واقعی نیز شناخته می شود، نسبت پیش بینی های مثبت واقعی در بین تمام نمونه های مثبت واقعی است. این به صورت زیر تعریف می شود:

$$\text{به یاد آوردن} = \frac{\text{تی پی}}{\text{تی پی} + \text{ف اف پی}}$$

و توانایی مدل را در شناسایی موارد واقعی حمله قلبی می سنجد. دستیابی به فراخوانی بالا برای اطمینان از تشخیص اکثر موارد حمله قلبی و به حداقل رساندن خطر از دست دادن تشخیص، مهم است.

- **امتیاز F1** میانگین هارمونیک دقت و فراخوانی است که یک معیار واحد ارائه می دهد که هر دو را متعادل می کند. این به صورت زیر تعریف می شود:

$$\text{امتیاز } F1 = 2 \times \frac{\text{دقت} \times \text{فراخوانی}}{\text{دقت} + \text{فراخوانی}}$$

- امتیاز F1 به ویژه زمانی مفید است که توزیع کلاس ها ناهموار باشد (مثلاً موارد غیر حمله قلبی بسیار بیشتر از موارد حمله قلبی باشد). این امتیاز تضمین می کند که هم مثبت کاذب و هم منفی کاذب در ارزیابی مدل در نظر گرفته شوند.
- **AUC** توانایی مدل را در تمایز بین کلاس های مثبت و منفی اندازه گیری می کند. این مساحت زیر منحنی ROC است که نرخ مثبت واقعی (TPR) را در مقابل نرخ مثبت کاذب (FPR) در تنظیمات آستانه مختلف رسم می کند. از نظر ریاضی، اغلب با استفاده از قاعده ذوزنقه ای به صورت زیر تقریب زده می شود:

$$AUC = \int_0^1 FPR(TPR) \, d(TPR)$$

منحنی ROC به صورت زیر تعریف می شود:

$$\text{تی پی آر} = \frac{\text{تی پی}}{\text{تی پی} + \text{اف پی}} \quad \text{نرخ بهره قدرال} = \frac{\text{اف پی}}{\text{اف پی} + \text{تنسی}}$$

### ۳.۵. محیط آزمایش و تنظیم ابرپارامتر

محیط آزمایشی این مطالعه به گونه ای طراحی شده بود که تجزیه و تحلیل قوی و تکرارپذیر پیش بینی حمله قلبی با استفاده از مدل های یادگیری ماشینی (DL) را تضمین کند. آزمایش ها بر روی دستگاهی با پردازنده Intel Core i7، 16 گیگابایت رم و یک پردازنده گرافیکی NVIDIA GeForce GTX 1060 برای تسریع آموزش مدل یادگیری ماشینی انجام شد. نرم افزار شامل پایتون 3.8 به عنوان زبان برنامه نویسی اصلی بود که از چندین کتابخانه کلیدی برای دستکاری داده ها، ساخت مدل و تجسم استفاده می کرد.

پردازش و دستکاری داده ها با استفاده از Pandas برای مدیریت کارآمد داده ها انجام شد، در حالی که Numpy برای محاسبات عددی به کار گرفته شد. Scikit-learn ابزارهایی را برای پیش پردازش داده ها، از جمله استانداردسازی و تقسیم مجموعه داده ها به مجموعه های آموزشی و آزمایشی، فراهم کرد. علاوه بر این، Scikit-learn در ارزیابی مدل نقش مهمی داشت و معیارهایی مانند دقت، صحت، فراخوانی، امتیاز F1 و AUC را برای ارزیابی جامع عملکرد مدل ارائه داد.

مدل های یادگیری ماشینی (DL) با استفاده از TensorFlow و Keras پیاده سازی شدند که ساخت، آموزش و ارزیابی معماری های شبکه عصبی، از جمله مدل های MLP، CNN، RNN، LSTM، GRU و Hybrid را تسهیل کردند. برای تجسم سازی، از Matplotlib و Seaborn برای ایجاد نمودارها استفاده شد. محیط آزمایش طوری تنظیم شد که اطمینان حاصل شود همه آزمایش ها قابل تکرار هستند و نتایج سازگار هستند و به اعتبار و پایایی کلی مطالعه کمک می کنند.

مجموعه داده ها به یک تقسیم بندی ۸۰-۲۰ برای آموزش-آزمون تقسیم شدند. این تقسیم بندی تضمین می کند که بخش قابل توجهی از داده ها برای آموزش مدل ها استفاده می شوند، در حالی که داده های باقی مانده برای آزمایش رزرو می شوند و امکان ارزیابی مستقل عملکرد مدل را فراهم می کنند. برای بهینه سازی عملکرد مدل، تنظیم ابرپارامتر با استفاده از جستجوی شبکه ای و اعتبارسنجی متقابل انجام می شود. جستجوی شبکه ای شامل ارزیابی سیستماتیک ترکیبات ابرپارامترها با آموزش مدل ها روی هر ترکیب و انتخاب بهترین مجموعه با عملکرد است. اعتبارسنجی متقابل شامل تقسیم داده های آموزشی به ۵ زیرمجموعه و آموزش مدل ک=۵ بار، هر بار با استفاده از زیرمجموعه ای متفاوت به عنوان مجموعه اعتبارسنجی و داده های باقی مانده برای آموزش. این فرآیند به اطمینان از اینکه مدل به خوبی به داده های دیده نشده تعمیم می یابد، کمک می کند. سپس هر مدل روی بخش آموزشی (۸۰٪) مجموعه داده ها با استفاده از ابرپارامترهای تنظیم شده آموزش داده شد. جدول ۳ پارامترهای بهینه ای را که مدل های DL انتخاب شده در طول اعتبارسنجی متقابل ۵ گانه با آن ها تنظیم شده اند، خلاصه می کند، با هدف به حداکثر رساندن معیارهای ارائه شده قبلی.

جدول ۳. بهترین پارامترها برای مدل های DL تنظیم شده اند.

مدل	پارامتر	بهترین ارزش
MLP	تعداد لایه های پنهان (واحد در هر لایه)	۳
	تابع فعال سازی نرخ یادگیری اندازه دسته	[64, 128, 64] ریلو ۰.۰۰۱ ۳۲
سی ان ان	تعداد فیلترهای لایه های کانولوشنی در هر لایه	۳
	اندازه هسته اندازه استخر تابع فعال سازی نرخ یادگیری اندازه دسته	[128, 64, 32] (3, 3) (2, 2) ریلو ۰.۰۰۱ ۳۲
آران ان	تعداد لایه های بازگشتی واحد در هر لایه	۲
	تابع فعال سازی نرخ یادگیری اندازه دسته	[64, 128] تان ۰.۰۰۱ ۳۲
LSTM	تعداد لایه های LSTM (واحد در هر لایه)	۲
	تابع فعال سازی نرخ یادگیری اندازه دسته	[64, 128] تان ۰.۰۰۱ ۳۲
جی آر یو	تعداد لایه های GRU واحد در هر لایه	۲
	تابع فعال سازی نرخ یادگیری اندازه دسته	[64, 128] تان ۰.۰۰۱ ۳۲
هیبریدی	تعداد فیلترهای لایه های کانولوشنی در هر لایه	۲
	اندازه هسته اندازه استخر تعداد واحدهای لایه های GRU به ازای هر تابع فعال سازی لایه GRU نرخ یادگیری اندازه دسته	[128, 64] (3, 3) (2, 2) ۲ [64, 128] GRU0.001 برای CNN، tanh برای ReLU ۳۲

#### ۴. نتایج و بحث

عملکرد هر مدل یادگیری ماشینی (DL) با استفاده از پنج معیار مهم ارزیابی شد: دقت، صحت، بازخوانی، امتیاز F1 و AUC. این معیارها بینش کاملی از مهارت مدل ها در پیش بینی حملات قلبی ارائه می دهند. نتایج این ارزیابی ها در جدول خلاصه شده است. <sup>۴</sup> این مقایسه عمیق، هم نقاط قوت هر مدل و هم حوزه های بالقوه برای بهبود را برجسته می کند.

جدول ۴. معیارهای عملکرد برای مدل های یادگیری عمیق (DL) در پیش بینی حمله قلبی

مدل	دقت	دقت	به یاد بیاورید	امتیاز F1	AUC
MLP	۰.۸۵	۰.۸۳	۰.۸۴	۰.۸۴	۰.۸۹
سی ان ان	۰.۸۷	۰.۸۵	۰.۸۶	۰.۸۵	۰.۹۱
آران ان	۰.۸۴	۰.۸۲	۰.۸۳	۰.۸۲	۰.۸۸
LSTM	۰.۸۸	۰.۸۶	۰.۸۷	۰.۸۷	۰.۹۲
جی آر یو	۰.۸۹	۰.۸۷	۰.۸۸	۰.۸۷	۰.۹۳
هیبریدی	۰.۹۱	۰.۸۹	۰.۹۰	۰.۸۹	۰.۹۵

مدل MLP به دقت 0.85، دقت 0.83، میزان بازخوانی 0.84، امتیاز F1 برابر با 0.84 و سطح زیرمنحنی (AUC) برابر با 0.89 دست یافت. اگرچه MLP عملکرد متعادلی را در تمام معیارها نشان داد، اما سطح زیرمنحنی (AUC) کمی پایین تر از آن نشان می دهد که اگرچه می تواند اکثر موارد را به درستی شناسایی کند، اما در تمایز بین موارد مثبت و منفی به اندازه کافی مؤثر نیست. این محدودیت را می توان به معماری مدل نسبت داد که نمی تواند الگوهای پیچیده در داده ها را به طور مؤثر مانند سایر مدل ها ثبت کند.

علاوه بر این، مدل CNN بهبود قابل توجهی نسبت به MLP نشان داد و به دقت 0.87، دقت 0.85، فراخوانی 0.86، امتیاز F1 0.85 و AUC 0.91 دست یافت. توانایی CNN در استخراج و بهره گیری از سلسله مراتب مکانی در داده ها احتمالاً به عملکرد بهبود یافته آن کمک می کند. AUC بالاتر این مدل نشان دهنده توانایی کلی بهتر در تمایز بین کلاس ها است و آن را به ویژه در سناریوهایی که استخراج ویژگی های مکانی حیاتی است، مفید می سازد.

در مقایسه، RNN با دقت 0.84، دقت 0.82، فراخوانی 0.83، امتیاز F1 0.82 و AUC 0.88 عملکرد مناسبی را نشان داد. معماری RNN که برای مدیریت داده های ترتیبی طراحی شده است، عملکرد خوبی دارد اما در مقایسه با CNN و مدل های بازگشتی پیشرفته تر، عملکرد ضعیف تری دارد. این نشان می دهد که اگرچه RNN ها می توانند وابستگی های زمانی را ثبت کنند، ساختار ساده تر آنها ممکن است برای ماهیت پیچیده داده های پیش بینی حمله قلبی کافی نباشد.

شبکه LSTM که برای رفع محدودیت های RNN های استاندارد طراحی شده بود، به دقت 0.88، دقت 0.86، فراخوانی 0.87، امتیاز F1 0.87 و AUC 0.92 دست یافت. توانایی LSTM در مدیریت وابستگی های بلندمدت از طریق مکانیسم های دروازه ای خود، در فراخوانی و امتیاز F1 برتر آن منعکس می شود. این نشان می دهد که LSTM به ویژه در شناسایی موارد مثبت واقعی مؤثر است و آن را به انتخابی قابل اعتماد برای تشخیص های پزشکی تبدیل می کند که در آن ها از دست دادن یک مورد مثبت می تواند عواقب شدیدی داشته باشد.

به طور خاص، مدل GRU با دقت 0.89، دقت 0.87، فراخوانی 0.88، امتیاز F1 0.87 و AUC 0.93 بهترین عملکرد را در بین مدل های منفرد نشان داد. مکانیسم دروازه بندی کارآمد GRU، که جریان اطلاعات را در مقایسه با LSTM ساده تر می کند، به آن اجازه می دهد تا ویژگی های مهم را حفظ کند و در عین حال ویژگی های نامربوط را کنار بگذارد. این تعادل بین سادگی و کارایی منجر به عملکرد کلی برتر می شود و GRU را به انتخابی عالی برای کارهایی که نیاز به پردازش داده های زمانی ظریف دارند، تبدیل می کند.

مدل هیبریدی از تمام مدل های منفرد پیشی گرفت و به بالاترین معیارها در بین سایر مدل های DL دست یافت: دقت ۰.۹۱، دقت ۰.۸۹، فراخوانی ۰.۹۰، امتیاز F1 0.89 و AUC 0.95. این مدل از قابلیت های استخراج ویژگی CNN ها و نقاط قوت پردازش زمانی GRU ها بهره می برد و به طور مؤثر وابستگی های مکانی و زمانی را ثبت می کند. عملکرد برتر مدل هیبریدی، پتانسیل ترکیب معماری های مختلف DL را برای پرداختن به ماهیت چندوجهی داده های پزشکی برجسته می کند. با ادغام حساسیت مکانی CNN ها با کارایی زمانی GRU ها، مدل هیبریدی چارچوبی قوی برای پیش بینی حملات قلبی با دقت و قابلیت اطمینان بالاتر ارائه می دهد.

یکی از اهداف مهم این کار، ارائه مقایسه ای جامع از پنج مدل برجسته یادگیری ماشینی (DL) در زمینه پیش بینی حمله قلبی بود. این امر محقق شد، همانطور که نتایج تجربی نشان می دهد، جایی که مدل هیبریدی عملکرد برتر را در تمام معیارها، به ویژه در دستیابی به بالاترین دقت (91٪) و (AUC 0.95) نشان داد. این یافته، رویکرد ما در ادغام CNN و GRU برای بهره برداری از داده های مکانی و زمانی را تأیید کرد و از عملکرد مدل های سنتی و برخی مدل های یادگیری ماشینی که در بخش 2 مورد بحث قرار گرفته است، پیشی گرفت. ۲.

علاوه بر این هدف، ما قصد داشتیم عملکرد قوی مدل را در طیف وسیعی از معیارها تضمین کنیم. نمرات بالای مداوم مدل هیبریدی در دقت، صحت، فراخوانی و امتیاز F1، نشان دهنده تحقق موفقیت آمیز این هدف بود و قابلیت اطمینان مدل را در پیش بینی خطرات حمله قلبی نشان داد. عملکرد برتر مدل هیبریدی نه تنها اثربخشی ترکیب معماری های CNN و GRU را برجسته می کند، بلکه پتانسیل این روش ها را در سایر وظایف پیش بینی پزشکی نیز نشان می دهد. این سهم به ویژه با در نظر گرفتن محدودیت های مدل های موجود قابل توجه است،



مانند مواردی که در بخش مورد بحث قرار گرفت<sup>۲</sup>، که در آن مدیریت داده های زمانی یا مکانی بهینه نبود.

هدف دیگر، افزایش قابلیت تفسیر مدل های DL بود. بنابراین، برای تفسیر بیشتر این مدل ها و درک فرآیند تصمیم گیری اساسی، مقادیر SHAP محاسبه شدند. SHAP به این سوال پاسخ می دهد که هر ویژگی چقدر در پیش بینی حمله قلبی نقش دارد. در جدول<sup>۵</sup>، میانگین مقادیر SHAP (در بین همه افراد) نشان داده شده است که نشان می دهد در تمام مدل های DL، ویژگی های حداکثر ضربان قلب، نوع درد قفسه سینه و تالاسمی به طور مداوم اهمیت بالایی را نشان داده اند و بنابراین، در تمام مدل ها بیشترین تأثیر را داشته اند. این ویژگی ها بیشترین تأثیر را بر پیش بینی های انجام شده توسط مدل های DL در زمینه پیش بینی حمله قلبی داشتند.

**جدول ۵.** میانگین مقادیر SHAP برای اهمیت ویژگی ها در هر مدل DL.

ویژگی	MLP	سی ان ان	آران ان	LSTM	جی آر یو	هیبریدی
سن	۰.۱۲	۰.۱۴	۰.۱۳	۰.۱۱	۰.۱۲	۰.۱۳
جنسیت	۰.۰۷	۰.۰۸	۰.۰۷	۰.۰۹	۰.۰۸	۰.۰۷
چست پی	۰.۱۸	۰.۲۱	۰.۲۰	۰.۱۹	۰.۲۰	۰.۲۲
استراحتی بی	۰.۱۱	۰.۱۲	۰.۱۱	۰.۱۳	۰.۱۲	۰.۱۱
چول	۰.۱۰	۰.۱۱	۰.۰۹	۰.۱۰	۰.۱۱	۰.۱۰
فست بی اس	۰.۰۴	۰.۰۵	۰.۰۴	۰.۰۶	۰.۰۵	۰.۰۴
استراحتوار قلب (RestECG)	۰.۰۶	۰.۰۷	۰.۰۸	۰.۰۷	۰.۰۶	۰.۰۷
مکس آج آر	۰.۲۰	۰.۱۹	۰.۲۱	۰.۲۲	۰.۲۰	۰.۲۱
ExIndAng	۰.۰۸	۰.۰۷	۰.۰۹	۰.۱۰	۰.۰۸	۰.۰۹
STDp	۰.۱۳	۰.۱۲	۰.۱۴	۰.۱۳	۰.۱۲	۰.۱۴
شیب	۰.۰۹	۰.۱۰	۰.۰۹	۰.۱۱	۰.۱۰	۰.۱۰
NMajV	۰.۱۱	۰.۱۲	۰.۱۰	۰.۱۱	۰.۱۲	۰.۱۱
تال	۰.۱۵	۰.۱۶	۰.۱۴	۰.۱۵	۰.۱۶	۰.۱۵

با ادغام مقادیر SHAP با معیارهای ارزیابی، ما نه تنها درک جامعی از عملکرد خوب مدل ها، بلکه دلیل انجام پیش بینی های خاص توسط آنها نیز به دست آوردیم و در نتیجه شفافیت و قابلیت تفسیر مدل های DL را در زمینه پیش بینی حمله قلبی افزایش دادیم. با شفاف سازی پیش بینی های مدل ها، متخصصان مراقبت های بهداشتی می توانند سیستم پیش بینی را بهتر درک و به آن اعتماد کنند و این امر منجر به تصمیم گیری آگاهانه تر می شود. این مطالعه ارزش ترکیب مدل های پیشرفته DL با تکنیک های XAI را برای توسعه سیستم های پیش بینی قابل اعتماد و قابل تفسیر برای تشخیص حمله قلبی نشان می دهد و در نهایت نتایج بیمار را از طریق پیش بینی زود هنگام و دقیق بهبود می بخشد. این هدف با موفقیت محقق شد، زیرا تجزیه و تحلیل SHAP بینش روشنی در مورد اهمیت ویژگی ها ارائه داد، به طوری که حداکثر ضربان قلب، نوع درد قفسه سینه و تالاسمی به طور مداوم در بین مدل ها تأثیرگذار بودند. این امر نه تنها با هدف ما برای کاربردی تر کردن مدل ها از نظر بالینی همسو است، بلکه رویکرد ما را از سایر مطالعاتی که در آنها قابلیت تفسیر کمتر مورد تأکید قرار گرفته بود، متمایز می کند.

## ۵. نتیجه گیری و کارهای آینده

این مطالعه با مقایسه عملکرد پنج مدل برجسته، یعنی CNN، RNN، LSTM، GRU و MLP و یک مدل ترکیبی که معماری های CNN و GRU را ادغام می کند، پتانسیل قابل توجه مدل های DL در پیش بینی حملات قلبی را نشان می دهد. یافته های ما نشان می دهد که تکنیک های پیشرفته DL می توانند دقت و قابلیت اطمینان پیش بینی های حمله قلبی را به طور قابل توجهی بهبود بخشند، که برای تشخیص زود هنگام و مداخله به موقع بسیار مهم است. علاوه بر این، دستیابی به بالاترین عملکرد در تمام معیارهای ارزیابی شده - دقت (91٪)، دقت (89٪)، فراخوانی (90٪)، امتیاز (F1) 89٪ و (AUC) 0.95 - اثربخشی مدل Hybrid تأیید شد و در نتیجه یک راه حل قوی در حوزه تشخیص پزشکی ارائه داد. نتایج AUC بالا نشان دهنده برتری مدل Hybrid در تمایز بین افراد مبتلا به حمله قلبی و غیر مبتلا به حمله قلبی بود. مکانیسم دروازه ای این مدل، که به طور موثر ویژگی های مهم را ثبت و حفظ می کند و در عین حال ویژگی های نامربوط را کنار می گذارد، احتمالاً به عملکرد قوی آن کمک کرده است. علاوه بر این، ادغام SHAP

این تکنیک درک عمیق تری از پیش بینی های مدل ارائه داد و شفافیت و کاربرد بالینی آنها را افزایش داد. هدف اصلی افزایش عملکرد و تفسیرپذیری مدل با موفقیت محقق شد، همانطور که با دقت برتر مدل هیبریدی و بینش های ارائه شده توسط تجزیه و تحلیل SHAP نشان داده شد. این نتایج نه تنها اهداف اولیه را برآورده کردند، بلکه از آنها فراتر رفتند و ابزاری عملی برای پزشکان ارائه دادند که قدرت پیش بینی را با شفافیت متعادل می کند. پیامدهای این تحقیق، به ویژه برای توسعه ابزارهای تشخیصی قابل اعتمادتر و تفسیرپذیرتر در مراقبت های بهداشتی، قابل توجه است.

اگرچه یافته های این مطالعه امیدوارکننده است، اما ضروری است که محدودیت های مجموعه داده های مورد استفاده را نیز در نظر گرفت. اندازه محدود مجموعه داده ها (موارد و ویژگی ها) ممکن است به دلیل اندازه محدود و دامنه جمعیتی خاص، به طور کامل نمایانگر جمعیت وسیع تر نباشد. اندازه نمونه نسبتاً کوچک، نگرانی هایی را در مورد پتانسیل بیش برآزش ایجاد می کند، که در آن مدل ممکن است روی داده های آموزشی عملکرد خوبی داشته باشد اما به طور مؤثر به داده های جدید تعمیم داده نشود. علاوه بر این، توزیع ویژگی هادر مجموعه داده ها، مانند محدوده سنی و نمایش جنسیت، ممکن است سوگیری هایی را ایجاد کند که بر پیش بینی های مدل تأثیر می گذارد. علاوه بر این، مجموعه داده ها فاقد اطلاعات دقیقی در مورد عواملی مانند وضعیت اجتماعی-اقتصادی، سابقه پزشکی، وجود سایر بیماری های همراه و متغیرهای سبک زندگی است که می توانند بر خطر حمله قلبی تأثیر بگذارند اما در این تحلیل لحاظ نشده اند. عدم وجود چنین عواملی که به طور قابل توجهی بر خطر حمله قلبی تأثیر می گذارند، این مطالعه را بیشتر محدود می کند. این محدودیت ها، نیاز به تحقیقات آینده با استفاده از مجموعه داده های بزرگتر و متنوع تر را برای افزایش استحکام، دقت، کاربردپذیری و تعمیم پذیری مدل های پیش بینی توسعه یافته در این مطالعه در محیط های بالینی مختلف برجسته می کند.

همکاری با متخصصان بالینی برای افزایش ارتباط عملی یافته های ما در محیط های دنیای واقعی ضروری است. این همکاری ها می توانند به صورت مرحله ای ساختار یافته شوند، که با اعتبارسنجی گذشته نگرا استفاده از داده های تاریخی بیمار شروع می شود و به مطالعات آینده نگر که در آن ها پیش بینی های مدل بر تصمیم گیری بالینی تأثیر می گذارد، می رسد. چالش های این همکاری ها شامل ادغام مدل در گردش های کاری بالینی، اطمینان از رعایت مقررات حفظ حریم خصوصی داده ها و پرداختن به شک و تردید اولیه ای است که ممکن است از سوی پزشکان ایجاد شود. یک حلقه بازخورد مداوم، که در آن از نتایج بالینی برای اصلاح مدل استفاده می شود، در قوی تر و قابل اعتمادتر کردن مدل ها برای کاربردهای دنیای واقعی بسیار مهم خواهد بود. چنین مشارکت های بین رشته ای کلید گذار از تحقیق به اجرای عملی و در نهایت بهبود نتایج بیمار خواهد بود.

پیامدهای عملی این تحقیق عمیق است. با ادغام مدل های یادگیری ماشینی (DL) در فرآیندهای تصمیم گیری بالینی، ارائه دهندگان خدمات درمانی می توانند از پیش بینی های دقیق تر و به موقع تر خطر حمله قلبی بهره مند شوند. این ادغام می تواند منجر به مراقبت شخصی سازی شده و پیشگیرانه از بیمار شود. در نهایت نتایج بیمار را بهبود بخشد و فشار بر سیستم های مراقبت های بهداشتی را کاهش دهد. علاوه بر این، تجزیه و تحلیل مقایسه ای ما بینش های ارزشمندی را برای محققان و پزشکان فراهم می کند و پیشرفت های آینده در زمینه تشخیص پزشکی را هدایت می کند.

در ادامه ی مطالعه ی فعلی، تجزیه و تحلیل دقیق تر چگونگی تعامل ویژگی های مجموعه داده ها به عنوان عوامل خطر با یکدیگر می تواند عمق قابل توجهی به درک ما از خطر حمله قلبی بیفزاید. علاوه بر این، جدا از معیارهای ارزیابی سنتی که در حال حاضر در نظر گرفته می شوند، یک جایگزین چالش برانگیز، ارزیابی پیچیدگی محاسباتی هر مدل با اندازه گیری زمان آموزش و میزان استفاده از منابع (مثلاً، میزان حافظه و میزان استفاده از GPU) خواهد بود. این تجزیه و تحلیل به درک امکان سنجی عملی استقرار این مدل ها در محیط های دنیای واقعی، که در آن منابع محاسباتی ممکن است محدود باشند و مجموعه داده های بزرگتر رایج هستند، کمک می کند. در حالی که مجموعه داده های انتخاب شده برای توسعه مدل مناسب است، اذعان می شود که مدل های DL عموماً از مجموعه داده های بزرگتر بهره می برند که امکان تعمیم و استحکام بهتر را فراهم می کنند. در کارهای آینده، مقیاس بندی مدل ها به مجموعه داده های بزرگتر برای اعتبارسنجی یافته ها و اطمینان از اینکه مدل ها می توانند پیچیدگی و تغییرپذیری فزاینده موجود در مجموعه داده های گسترده تر را مدیریت کنند، ضروری خواهد بود. در ادامه، تحقیقات آینده بر بررسی ادغام سایر تکنیک های پیشرفته ML/DL با روش های مختلف XAI تمرکز خواهد کرد تا استحکام و کاربرد مدل های پیش بینی کننده را در محیط های بالینی بیشتر افزایش دهد.

این مطالعه به عنوان یک کاوش بنیادی عمل می کند، با این انتظار که تکنیک ها و بینش های توسعه یافته در اینجا برای محیط های داده بزرگتر قابل مقیاس بندی باشند تا جمعیت های متنوع تری از بیماران را در بر بگیرند و ویژگی های مرتبط بیشتری را برای افزایش بیشتر عملکرد مدل در خود جای دهند.

**مشارکت های نویسنده:** ایده را مطرح کردند، آزمایش ها را طراحی و اجرا کردند، نتایج را تجزیه و تحلیل کردند، پیش نویس اولیه را تهیه کردند و نسخه نهایی را اصلاح کردند. همه نویسندگان نسخه منتشر شده مقاله را خوانده و با آن موافقت کرده اند MT و ED

**تأمین مالی:** این تحقیق هیچ بودجه خارجی دریافت نکرده است.

**بیانیه دسترسی به داده ها:** مقالات اصلی ارائه شده در این مطالعه در مقاله گنجانده شده است، سوالات بیشتر را می توان با نویسنده مسئول در میان گذاشت.

**تضاد منافع:** نویسندگان هیچ گونه تضاد منافعی را اعلام نمی کنند.

## منابع

۱. بیماری های قلبی عروقی. به صورت آنلاین موجود است: [https://www.who.int/health-topics/cardiovascular-diseases#tab=tab\\_1](https://www.who.int/health-topics/cardiovascular-diseases#tab=tab_1) (دسترسی در ۳۱ ژوئیه ۲۰۲۴).
۲. ملاینتان، س. اوبرمایر، ز. چه کسی برای حمله قلبی آزمایش می شود و چه کسی باید آزمایش دهد: پیش بینی خطر بیمار و خطای پزشک؛ دفتر ملی تحقیقات اقتصادی؛ کمبریج، ماساچوست، ایالات متحده آمریکا، ۲۰۱۹.
۳. گونگ، اف. اف؛ وایتاس، آی.؛ مالایسری، اس. سی.؛ ماگانتی، کی. عوارض مکانیکی انفارکتوس حاد میوکارد: یک بررسی. *جاما کاردیول*. ۲۰۲۱، ۶، ۳۴۱-۳۴۹. [کراس رف] [پاب مد]
۴. مکانیک، او. جی؛ گاوین، ام.؛ گراسمن، اس. ای.؛ زیگلر، کی. انفارکتوس حاد میوکارد (پرستاری). *دراسات پیرز [اینترنت]*. سنت پترزبورگ، فلوریدا، ایالات متحده آمریکا، StatPearls Publishing: 2023.
۵. سالیر، جی.؛ فلاتری، ام.؛ لیون، دی. ای. خوشه های علائم نارسایی قلبی و کیفیت زندگی. *قلب و ریه*. ۲۰۱۹، ۴۸، ۳۶۶-۳۷۲. [کراس رف] [پاب مد]
۶. هان، سی. اچ؛ کیم، اچ؛ لی، اس؛ چانگ، جی. اچ. دانش و درک ضعیف از عوامل سکتة مغزی و علائم حمله قلبی. *مجله بین المللی تحقیقات محیط زیست، بهداشت عمومی*. ۲۰۱۹، ۱۶، ۳۶۶۵. [کراس رف] [پاب مد]
۷. لیبی، پ. *کتاب الکترونیکی بیماری های قلبی برونوالد: درسنامه پزشکی قلب و عروق؛ علوم سلامت الزویر؛ آمستردام، هلند*. ۲۰۲۱.
۸. تروبی، ال. کی؛ راجرز، جی. جی. نارسایی پیشرفته قلب: اپیدمیولوژی، تشخیص و رویکردهای درمانی. *نارسایی قلبی*. ۲۰۲۰، ۱، ۵۲۳-۵۳۶.
۹. کائول، د.؛ راجو، ه.؛ تری پاتی، ب. یادگیری عمیق در مراقبت های بهداشتی. *دریادگیری عمیق در تجزیه و تحلیل داده ها: تکنیک ها، شیوه ها و کاربردهای اخیر؛ اشپرینگر؛ برلین/هایدلبرگ، آلمان*. ۲۰۲۲؛ صفحات ۹۷-۱۱۵.
۱۰. احسان، م.؛ صدیق، ز. تشخیص بیماری قلبی مبتنی بر یادگیری ماشین: یک بررسی سیستماتیک متون. *مصنوع. هوشمند. پزشکی*. ۲۰۲۲، ۱۲۸، ۱۰۲۲۸۹. [کراس رف]
۱۱. Van 11. *تجزیه و تحلیل تصویر پزشکی مبتنی بر یادگیری عمیق (XAI) هوش مصنوعی قابل توضیح*. Gilhuijs, KG; Viergever, MA; Kooft, AJ; der Velden, BH. *تصویر تحلیلی*. ۲۰۲۲، ۷۹، ۱۰۲۴۷۰. [کراس رف]
۱۲. صالح، ای. ام؛ رئیس-استبرق، زی.؛ گلازو، آی. بی.؛ رادوا، پی.؛ پترسن، اس. ای.؛ لکادیر، کی.؛ منه گر، جی. نگاهی به روش های هوش مصنوعی قابل توضیح: SHAP و LIME. *هوش پیشرفته. سیستم*. ۲۰۲۴، ۲۴۰۰۳۰۴. [کراس رف]
۱۳. احمد، س.؛ کایزر، م. س.؛ حسین، م. س.؛ اندرسون، ک. تحلیل مقایسه ای مفسرهای LIME و SHAP با پیش بینی های دیابت مبتنی بر یادگیری ماشین قابل توضیح. *دسترسی IEEE*. ۲۰۲۴، ۲۰۲۴۴-۲۲۴۸. [کراس رف]
۱۴. اشرف، م.؛ رضوی، م.؛ شارما، ج. بهبود پیش بینی بیماری قلبی با استفاده از شبکه عصبی عمیق. *مجله علوم کامپیوتر و فناوری آسیا*. ۲۰۱۹، ۱، ۴۹-۵۴. [کراس رف]
۱۵. هارکولاک، ن.؛ نادکاری، س.؛ پاتل، ب.؛ جادهاو، آ. پیش بینی بیماری قلبی با استفاده از مدل یادگیری عمیق CNN. *مجله بین المللی پژوهش های کاربردی علوم مهندسی فناوری*. ۲۰۲۰، ۸۱، ۸۷۵-۸۸۱. [کراس رف]
۱۶. برهوم، AMA؛ المصری، A.؛ ابوناصر، BS؛ ابوناصر، SS پیش بینی بیماری قلبی با استفاده از مجموعه ای از الگوریتم های یادگیری ماشین و عمیق. *مجله بین المللی مهندسی، سیستم اطلاعات (IJEAS)*. ۲۰۲۲، ۶، ۱-۱۳.
۱۷. پاندا، آر. ان.؛ زهیرا، اف. پیش بینی بیماری قلبی با استفاده از شبکه های عصبی کانولوشن عمیق. *مجله کامپیوتر، ریاضی و آموزش ترکیه (TURCOMAT)*. ۲۰۱۹، ۱۱۴۱-۱۱۴۸.
۱۸. بهارتی، ر.؛ خمپاریا، آ.؛ شاباز، م.؛ دهیمان، گ.؛ پانده، س.؛ سینگ، پ. پیش بینی بیماری قلبی با استفاده از ترکیبی از یادگیری ماشین و یادگیری عمیق. *کامپیوتر، هوش، علوم اعصاب*. ۲۰۲۱، ۲۰۲۱، ۸۳۸۷۶۸۰. [کراس رف] [پاب مد]
۱۹. شارما، س.؛ پارمار، م. پیش بینی بیماری های قلبی با استفاده از مدل شبکه عصبی یادگیری عمیق. *بین المللی Innov. J. تکنولوژی کاوش کنید. مهندس (IJITEE)*. ۲۰۲۰، ۹، ۲۲۴۴-۲۲۴۸. [کراس رف]
۲۰. سارما، اس. اس. یک سیستم کارآمد نظارت بر بیمار و پیش بینی بیماری قلبی مبتنی بر اینترنت اشیا با استفاده از شبکه عصبی اصلاح شده با یادگیری عمیق. *دسترسی IEEE*. ۲۰۲۰، ۱۳۵۷۸۴-۱۳۵۷۹۷. [کراس رف]
۲۱. پاشا، اس. ان.؛ رامش، دی.؛ محمد، اس.؛ هارشاواردان، ای. پیش بینی بیماری های قلبی عروقی با استفاده از تکنیک های یادگیری عمیق. در مجموعه مقالات کنفرانس IOP: علوم و مهندسی مواد، چنای، هند، ۱۶-۱۷ سپتامبر ۲۰۲۰؛ انتشارات IOP: بریستول، انگلستان، ۲۰۲۰؛ جلد ۹۸۱، صفحه ۰۲۲۰۶.

۲۲. وقار، م.؛ داوود، ج.؛ داوود، ح.؛ مجید، ن.؛ بنجار، ا.؛ الهربی، ر. یک مدل یادگیری عمیق کارآمد مبتنی بر SMOTE برای پیش بینی حمله قلبی. *برنامه علمی*. ۲۰۲۱، ۲۰/۲۱، ۶۶۲۱۶۲۲. [کراس رف]
۲۳. لاتا، سی بی سی؛ جیوا، اس سی. بهبود دقت پیش بینی خطر بیماری قلبی بر اساس تکنیک های طبقه بندی گروهی. *اطلاع رسانی پزشکی. قفل گشایی شده* ۱۶، ۲۰۱۹، ۱۰۰۲۰۳. [کراس رف]
۲۴. مجموعه داده های بیماری های قلبی. به صورت آنلاین در دسترس است: <https://github.com/AbdulrakeeB/Heart-disease-dataset/tree/main> (دسترسی در ۱۶ آگوست ۲۰۲۴).
۲۵. مجموعه داده های بیماری های قلبی از پنج پایگاه داده. به صورت آنلاین در دسترس است: <https://dataport.org/open-access/heart-disease-datasetcomprehensive> (دسترسی در ۱۶ آگوست ۲۰۲۴).
۲۶. مجموعه داده های بیماری های قلبی از چهار پایگاه داده. به صورت آنلاین موجود است: <https://archive.ics.uci.edu/dataset/45/heart+disease> (دسترسی در ۱۶ آگوست ۲۰۲۴).
۲۷. حیدر، آ.؛ بنگس، س.؛ لو، ج.؛ استو، ای.؛ سیلر-ماتولا، ج.م.؛ موکا، ت.؛ گبهارد، س. جنس و جنسیت در پزشکی قلب و عروق: تظاهرات و پیامدهای سندرم حاد کرونری. *یورو. هارت جی*. ۲۰۲۰، ۴/۱، ۱۳۳۶-۱۳۳۸. [کراس رف]
۲۸. کروزه، آر. مستقیم، س. بورگلت، سی. براون، سی. Steinbrecher، M. پرسپترون های چند لایه. *دروهوش محاسباتی: مقدمه ای روش شناختی؛ اشپرینگر: برلین/هایدلبرگ، آلمان*، ۲۰۲۲؛ صفحات ۵۳-۱۲۴.
۲۹. وستیس، نماینده مجلس، شبکه عصبی کانولوشن. *دردایره المعارف علوم و فناوری اطلاعات*، ویرایش پنجم؛ IGI Global: Hershey, PA، ایالات متحده آمریکا، ۲۰۲۱؛ ص ۱۲-۲۶.
۳۰. کاناگاییدامبارسان، جی.؛ روالی، ای.؛ بانرجی، دی.؛ پراکاش، کی.بی. شبکه عصبی بازگشتی. *درباره نویسی با TensorFlow: راهکاری برای کاربردهای محاسبات لبه ای؛ اشپرینگر: برلین/هایدلبرگ، آلمان*، ۲۰۲۱؛ صفحات ۵۳-۶۱.
۳۱. ون هودت، جی.؛ موسکرا، سی.؛ ناپولس، جی. مروری بر مدل حافظه بلندمدت کوتاه مدت. *هوشمند. کشیش*. ۲۰۲۰، ۵/۳، ۵۹۵۵-۵۹۲۹. [کراس رف]
۳۲. دوتا، آ.؛ کومار، س.؛ باسو، م. رویکرد واحد بازگشتی دروازه ای برای پیش بینی قیمت بیت کوین. *مجله مدیریت مالی ریسک*. ۲۰۲۰، ۱۳/۳. [کراس رف]
۳۳. رینیو، او.؛ توهو، جی.؛ کلن، آر. معیارهای ارزیابی و آزمون های آماری برای یادگیری ماشین. *نماینده علمی* ۱۴، ۲۰۲۴، ۶۰۸۶. [کراس رف] [پاب مد]

**سلب مسئولیت/یادداشت ناشر:** اظهارات، نظرات و داده های موجود در تمام نشریات صرفاً متعلق به نویسنده (گان) و مشارکت کننده (گان) است و نه MDPI و/یا سردبیر (گان). MDPI و/یا سردبیر (گان) مسئولیت هرگونه آسیب به افراد یا اموال ناشی از هرگونه ایده، روش، دستورالعمل یا محصولی که در محتوا به آن اشاره شده است را از خود سلب می کنند.